

Trabajo Fin de Grado - Curso 2025/ 2026

Planificación de rutas peatonales de mínima exposición a contaminación atmosférica mediante aprendizaje profundo

Autor: **Carlos Cañas García-Moreno**

Tutor: MARIA ROSER BENAVENT GARCIA

Facultat de Ciències Matemàtiques

Grado en Matemáticas

Resumen

Este Trabajo Fin de Grado desarrolla un marco matemático para la planificación de rutas peatonales que minimicen la exposición a la contaminación atmosférica en la ciudad de València, combinando técnicas de aprendizaje profundo con algoritmos clásicos de optimización sobre grafos. A partir de series temporales de calidad del aire obtenidas en el marco del proyecto CITCOM.AI, se diseña un pipeline reproducible que abarca el preprocesamiento de datos (limpieza, estudio de valores faltantes e imputación), la construcción de un campo espacial continuo de concentración de dióxido de nitrógeno (NO_2) mediante interpolación por ponderación inversa de la distancia (IDW), la predicción a corto plazo de su evolución temporal mediante una red de memoria a largo y corto plazo (LSTM) y la generación de escenarios sintéticos de estrés ambiental mediante una red generativa adversaria (GAN) condicional. Estos elementos se integran en un funcional de exposición sobre la red viaria de la ciudad, de manera que el cálculo de rutas de mínima exposición se reduce a un problema de caminos mínimos en un grafo ponderado. Los resultados empíricos, obtenidos sobre una decena de pares origen–destino representativos, muestran que la optimización por exposición reduce de forma sistemática la dosis acumulada de NO_2 frente a la ruta de menor tiempo, y que la incorporación de predicción temporal mediante LSTM aporta una ventaja adicional significativa en escenarios de contaminación más severa y dinámica, mientras que dicha ventaja se diluye en condiciones ambientales estables. El trabajo articula así, dentro de un marco matemático unificado, la interpolación espacial, la predicción secuencial, la generación de escenarios sintéticos y la optimización de caminos mínimos aplicados a un problema concreto de movilidad urbana saludable.

Palabras clave: calidad del aire, planificación de rutas, aprendizaje profundo, redes LSTM, redes generativas adversarias, interpolación espacial, caminos mínimos, dióxido de nitrógeno, ciudades inteligentes.

Abstract

This Bachelor's Thesis develops a mathematical framework for planning pedestrian routes that minimise exposure to air pollution in the city of València, combining deep learning techniques with classical graph optimisation algorithms. Building on air quality time series obtained through the CITCOM.AI project, a reproducible pipeline is designed that covers data preprocessing (cleaning, missing-value analysis and imputation), the construction of a continuous spatial field of nitrogen dioxide (NO_2) concentration via inverse distance weighting (IDW) interpolation, short-term forecasting of its temporal evolution by means of a Long Short-Term Memory (LSTM) network, and the generation of synthetic environmental stress scenarios through a conditional Generative Adversarial Network (GAN). These elements are integrated into an exposure functional defined over the city's pedestrian network, so that computing minimum-exposure routes reduces to a shortest-path problem on a weighted graph. Empirical results, obtained over ten representative origin–destination pairs, show that exposure-based optimisation systematically reduces the accumulated NO_2 dose compared with the fastest route, and that incorporating LSTM-based temporal prediction provides a significant additional advantage under more severe and dynamic pollution scenarios, while this advantage vanishes under stable environmental conditions. The work thus articulates, within a unified mathematical framework, spatial interpolation, sequential prediction, synthetic scenario generation and shortest-path optimisation applied to a concrete problem of healthy urban mobility.

Keywords: air quality, route planning, deep learning, LSTM networks, generative adversarial networks, spatial interpolation, shortest paths, nitrogen dioxide, smart cities.

Índice

1 Introducción **1**
- 1.1 Motivación y contexto . . . 1
- 1.2 Definición del problema . . . 2
- 1.3 Objetivos del trabajo . . . 2
- 1.4 Metodología general del proyecto . . . 3
- 1.5 Estructura de la memoria . . . 3
- 1.6 Estado del arte . . . 5

2 Datos y preprocesamiento **7**
- 2.1 Descripción de los datos . . . 7
- 2.2 Análisis exploratorio de los datos . . . 9
- 2.3 Valores faltantes y tipos de *missingness* . . . 12
- 2.4 Imputación de valores faltantes . . . 14
- 2.5 Escalado de variables . . . 16
- 2.6 Síntesis del preprocesamiento y elección operativa del dióxido de nitrógeno . . . 17

3 Fundamentos matemáticos del aprendizaje profundo **19**
- 3.1 Problema de aprendizaje supervisado y riesgo de generalización . . . 19
- 3.2 Redes neuronales como funciones paramétricas . . . 22
- 3.3 Entrenamiento mediante gradiente y retropropagación . . . 24
- 3.4 Capacidad del modelo, sobreajuste y regularización . . . 26

4 Modelo espacial de calidad del aire y formulación de rutas de mínima exposición **28**
- 4.1 Representación espacial de las estaciones . . . 28
- 4.2 Interpolación por ponderación inversa de la distancia . . . 30
- 4.3 Red viaria y coste de exposición . . . 31

5 Modelo secuencial para la predicción temporal de concentraciones **34**
- 5.1 Formulación del problema de predicción temporal . . . 34
- 5.2 La arquitectura de memoria a largo y corto plazo . . . 35
- 5.3 Arquitectura y esquema de entrenamiento utilizados . . . 37

6 Modelo generativo para la construcción de escenarios de estrés **40**
- 6.1 Motivación: escenarios de estrés del dióxido de nitrógeno . . . 40
- 6.2 Esquema básico de una red generativa adversaria condicional . . . 41
- 6.3 Configuración utilizada en este trabajo . . . 41
- 6.4 Integración de la red generativa adversaria en el *pipeline* de rutas . . . 43

7 Resultados empíricos en rutas de mínima exposición **45**
7.1 Resultados agregados sin escenario generativo adversario 46
7.2 Resultados agregados con escenario generativo adversario temporal 46
7.3 Comparación global de ambos experimentos 47
7.4 Casos representativos para la memoria 47

8 Conclusiones y líneas futuras **55**
8.1 Resumen de la contribución 55
8.2 Conclusiones principales 56
8.3 Limitaciones del estudio 56
8.4 Líneas de trabajo futuro 57

Bibliografía **58**

Capítulo 1

Introducción

1.1 Motivación y contexto

En los últimos años, la disponibilidad de datos urbanos ha crecido de forma muy notable. La combinación de redes de sensores, portales de datos abiertos y servicios digitales municipales permite registrar de manera continua fenómenos muy diversos: intensidad del tráfico, variables meteorológicas, niveles de ruido, ocupación del espacio público o concentración de contaminantes atmosféricos. Este cambio no solo ha ampliado la cantidad de información disponible, sino también la posibilidad de utilizarla para apoyar decisiones urbanas con fundamento cuantitativo.

En este marco aparece el concepto de *ciudad inteligente*. Una definición clásica es la de Caragliu, Del Bo y Nijkamp, quienes describen estas ciudades como entornos urbanos en los que la inversión en capital humano y social, junto con las infraestructuras de comunicación y las tecnologías de la información, se traduce en desarrollo sostenible, mejora de la calidad de vida y gestión eficiente de los recursos públicos [14]. Bajo esta perspectiva, la información urbana deja de ser un mero registro administrativo y pasa a convertirse en una herramienta para la planificación y la toma de decisiones.

Entre los ámbitos donde esta disponibilidad de datos resulta más relevante se encuentra la calidad del aire. La exposición continuada a contaminantes atmosféricos se asocia a efectos adversos sobre la salud, especialmente en el sistema respiratorio y cardiovascular, tal y como recogen las guías de calidad del aire de la Organización Mundial de la Salud [15] y revisiones epidemiológicas de largo plazo [16]. Por ello, disponer de medidas ambientales de buena calidad no es únicamente una cuestión técnica, sino también una cuestión de interés social y sanitario.

La ciudad de València constituye un caso de estudio adecuado dentro de este contexto. En particular, el proyecto CITCOM.AI proporciona un marco especialmente pertinente para este trabajo, ya que se orienta al uso de datos urbanos y técnicas de inteligencia artificial para abordar retos de ciudad inteligente, entre ellos la movilidad y la sostenibilidad urbana [17]. Sin embargo, aunque la información exista y sea accesible, su utilización práctica por parte de peatones y ciclistas sigue siendo limitada: habitualmente se ofrece en forma de paneles, series temporales o mapas estáticos, mientras que las aplicaciones de navegación cotidiana priorizan casi exclusivamente criterios de distancia o tiempo de recorrido.

A partir de esta observación surge la motivación central de este trabajo: estudiar si es posible combinar herramientas matemáticas, modelos predictivos y algoritmos sobre grafos para construir rutas peatonales que, sin perder de vista el tiempo de viaje, tengan también en cuenta la exposición ambiental esperada. El interés del problema es doble. Por una parte, plantea una aplicación concreta de la ciencia de datos urbana; por otra, permite desarrollar con detalle un marco matemático que conecte interpolación espacial, modelización temporal y optimización de caminos.

1.2 Definición del problema

Desde un punto de vista conceptual, el problema puede formularse del modo siguiente. Se dispone de observaciones ambientales recogidas en un número finito de estaciones distribuidas por la ciudad y de una representación de la red de calles como grafo. A partir de esta información se desea construir un sistema que permita asociar a cada tramo de calle un coste ambiental y, con ello, recomendar trayectorias peatonales que reduzcan la exposición acumulada sin generar tiempos de desplazamiento desproporcionados.
Más concretamente, el problema presenta tres dificultades matemáticas y computacionales principales. En primer lugar, las mediciones ambientales son discretas en el espacio y en el tiempo: no se dispone directamente de un campo continuo sobre toda la ciudad, sino de valores puntuales observados en las estaciones. En segundo lugar, el fenómeno tiene naturaleza dinámica: las concentraciones cambian con el tiempo, por lo que una ruta razonable en un instante puede dejar de serlo en otro. En tercer lugar, el criterio de optimización no coincide con el criterio clásico de mínimo tiempo, sino que incorpora una magnitud acumulativa de exposición que debe definirse con cuidado.
Por tanto, el problema no consiste únicamente en "dibujar" una ruta diferente sobre un mapa, sino en encadenar varias etapas: preparar y caracterizar los datos, representar espacialmente la información ambiental, estimar su evolución temporal y, finalmente, resolver un problema de caminos mínimos sobre un grafo con pesos dependientes del contexto ambiental.

1.3 Objetivos del trabajo

El objetivo general de este Trabajo Fin de Grado (en adelante, TFG) es desarrollar un marco de trabajo reproducible y matemáticamente fundamentado para la planificación de rutas peatonales sensibles a la calidad del aire en la ciudad de València.
De este objetivo general se derivan los siguientes objetivos específicos:

(a) **Diseñar un pipeline de datos reproducible.** Unificar la carga de datos ambientales, limpiar registros, estudiar la presencia de valores faltantes, justificar la estrategia de imputación adoptada y homogeneizar la escala de las variables relevantes.

(b) **Construir una representación espacial del problema.** Pasar de observaciones puntuales en estaciones a un campo continuo sobre el plano urbano, de modo que sea posible evaluar la calidad ambiental en cualquier punto de la red peatonal.

(c) **Desarrollar un modelo secuencial de predicción a corto plazo.** Formular la predicción temporal como un problema supervisado sobre series temporales y estudiar una arquitectura recurrente adecuada para anticipar la evolución de la variable objetivo.

(d) **Incorporar un modelo generativo para escenarios de estrés.** Explorar la construcción de escenarios sintéticos plausibles que permitan estudiar la robustez de las rutas obtenidas cuando el campo ambiental presenta situaciones especialmente desfavorables.

(e) **Definir un funcional de exposición sobre rutas.** Traducir el problema aplicado a una formulación matemática sobre grafos, en la que cada arista posea un coste ligado a la exposición acumulada a lo largo del recorrido.

(f) **Comparar estrategias estáticas y dinámicas.** Analizar, sobre casos de estudio concretos, las diferencias entre rutas basadas en un campo ambiental fijo y rutas que incorporan información predictiva.

1.4 Metodología general del proyecto

La metodología seguida responde al esquema habitual de un proyecto de modelización de datos, pero adaptado a un problema urbano con componente espacial y temporal. De forma resumida, el trabajo se organiza en las fases siguientes:

- **Recopilación y caracterización de datos.** Identificación de las fuentes, descarga de los conjuntos de datos ambientales, revisión de su estructura y análisis de su cobertura temporal y espacial.
- **Preprocesamiento.** Limpieza de registros, estudio de valores ausentes, imputación justificada y escalado de variables cuando resulta necesario para el entrenamiento de modelos.
- **Modelización espacial.** Construcción de un campo continuo a partir de mediciones puntuales y definición del coste ambiental asociado a los tramos de la red urbana.
- **Modelización temporal.** Entrenamiento de un modelo secuencial que permita obtener predicciones a corto plazo de la variable de estudio.
- **Generación de escenarios sintéticos.** Uso de un modelo generativo con el fin de disponer de situaciones de estrés ambiental plausibles, útiles para evaluar la sensibilidad de las rutas.
- **Optimización de rutas y análisis crítico.** Resolución del problema de caminos mínimos bajo distintos escenarios y comparación de resultados desde la doble perspectiva de tiempo y exposición.

Estas fases no deben entenderse como un proceso completamente lineal. En la práctica, la preparación de datos, la elección de variables, el ajuste de parámetros y la interpretación de resultados obligan a iterar varias veces sobre el mismo esquema. Precisamente por ello, una parte importante del trabajo consiste en justificar matemáticamente cada decisión, y no solo en presentar el resultado final.

1.5 Estructura de la memoria

La memoria se ha organizado buscando un equilibrio entre fundamento matemático y aplicación al caso de València.

- En el **Capítulo 1** se presenta el contexto del problema, sus objetivos, la metodología general y una revisión sintética del estado del arte.
- En el **Capítulo 2** se describen las fuentes de datos, su estructura, el análisis exploratorio realizado y las decisiones de preprocesamiento que conducen al conjunto de trabajo definitivo.
- En el **Capítulo 3** se introducen los fundamentos matemáticos del aprendizaje profundo necesarios para formalizar los modelos utilizados posteriormente.
- En el **Capítulo 4** se desarrolla la representación espacial del problema, incluyendo la interpolación y la definición del coste de exposición sobre la red peatonal.
- En el **Capítulo 5** se estudia el modelo secuencial empleado para la predicción temporal.
- En el **Capítulo 6** se presenta el modelo generativo utilizado para construir escenarios sintéticos de estrés.
- En el **Capítulo 7** se muestran los resultados empíricos obtenidos en varios casos de estudio representativos y se discuten sus implicaciones.
- Finalmente, en el **Capítulo 8** se recogen las conclusiones, las limitaciones del trabajo y varias posibles líneas de extensión.

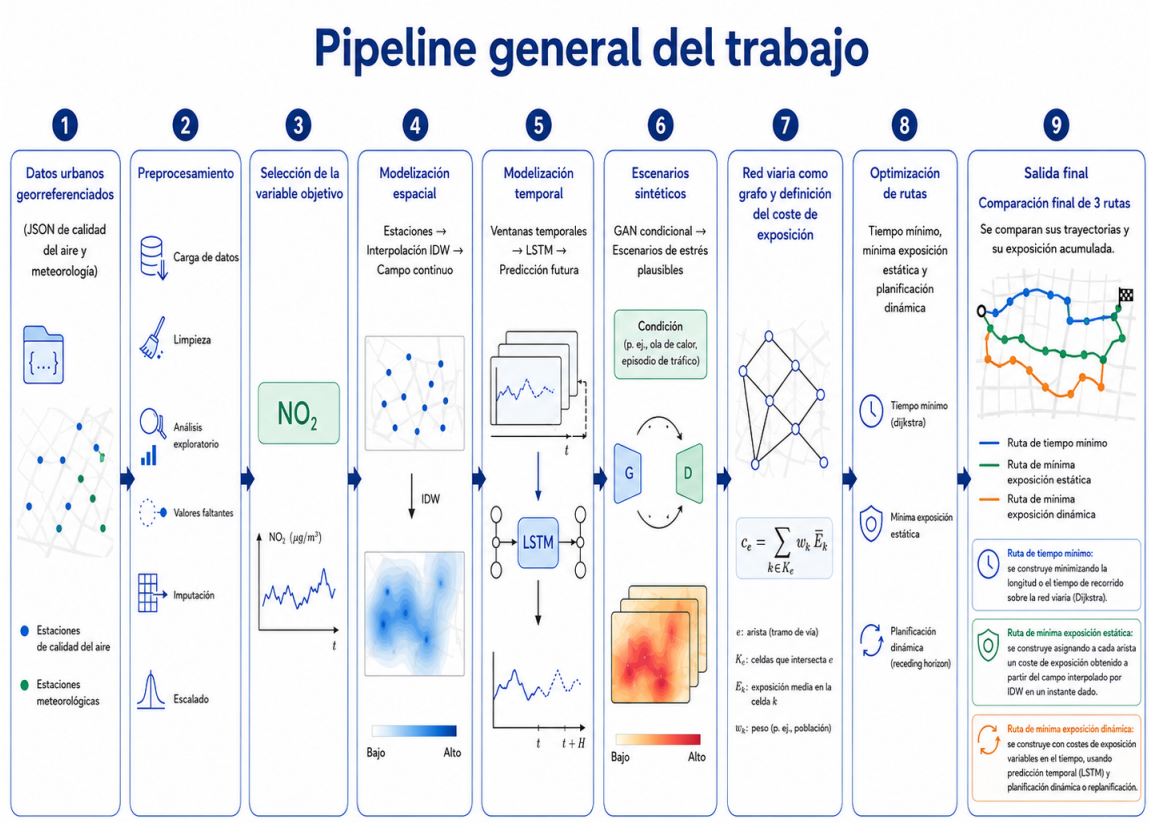


Figura 1.1: Esquema general de la metodología seguida en el trabajo: preparación de datos urbanos georreferenciados, preprocesamiento, selección de la variable objetivo, modelización espacial, predicción temporal, generación de escenarios sintéticos, definición del coste de exposición sobre la red viaria y comparación final de rutas.

1.6 Estado del arte

El problema estudiado en este trabajo se sitúa en la intersección de varias líneas de investigación. No existe una única tradición bibliográfica que lo agote por completo: confluyen la modelización de calidad del aire, la predicción temporal mediante aprendizaje profundo, la planificación de rutas con criterios ambientales y, más recientemente, el uso de modelos generativos para construir escenarios sintéticos.

Modelización urbana de la calidad del aire

En el ámbito de las ciudades inteligentes, la calidad del aire se ha convertido en una variable de especial interés por su relación con la salud pública y por su dependencia de fenómenos urbanos como el tráfico o la morfología de la ciudad. La red de estaciones permite observar tendencias, comparar zonas y detectar episodios desfavorables, pero la representación espacial sigue siendo un reto cuando las observaciones son puntuales. Por ello, una parte de la literatura se ha centrado en métodos de interpolación y en estrategias para pasar de medidas discretas a campos continuos de concentración [7, 6].

Predicción temporal con aprendizaje profundo

Una segunda línea de trabajo se ocupa de anticipar la evolución temporal de la calidad del aire. Frente a modelos estadísticos clásicos, los enfoques basados en aprendizaje profundo han mostrado especial utilidad cuando existen relaciones no lineales y dependencias de medio o largo alcance. En esta literatura destacan, entre otras, las arquitecturas recurrentes y, en particular, las redes de memoria a largo plazo (*Long Short-Term Memory*, LSTM), introducidas por Hochreiter y Schmidhuber [4] y desarrolladas posteriormente para mejorar la gestión de la memoria en secuencias largas [5]. En el contexto ambiental, distintos trabajos muestran que estas arquitecturas pueden utilizarse tanto en configuraciones multivariantes como en configuraciones univariantes, dependiendo de la calidad y disponibilidad de las covariables [12, 1, 2].

Planificación de rutas con criterios ambientales

Una tercera línea de investigación estudia cómo integrar la exposición a contaminantes en problemas de movilidad activa. Frente a la navegación convencional, que minimiza casi exclusivamente tiempo o distancia, estas propuestas introducen pesos ambientales sobre la red viaria para obtener rutas más saludables. Existen herramientas y estudios de caso en distintas ciudades que muestran que es posible reducir la exposición acumulada con incrementos moderados del recorrido, especialmente cuando se combinan información geográfica, datos ambientales e información de movilidad [9, 10, 11].

Escenarios sintéticos y modelos generativos

Por último, en años recientes se ha explorado el uso de modelos generativos adversarios (*Generative Adversarial Networks*, GAN) para producir mapas o series sintéticas consistentes con distribuciones observadas. Aunque esta línea es más reciente que las anteriores, resulta especialmente interesante cuando se desea estudiar la robustez de un sistema ante situaciones menos frecuentes o más severas que las observadas habitualmente. En el ámbito ambiental, estos modelos se han empleado tanto con fines predictivos como para generar realizaciones sintéticas plausibles de campos contaminantes [8, 13].

Síntesis

A la vista de esta literatura, el interés de este Trabajo Fin de Grado no reside en proponer una arquitectura completamente nueva, sino en articular de forma coherente varios bloques ya consolidados:

preparación rigurosa de datos, representación espacial, predicción secuencial y optimización de rutas. El valor añadido del trabajo se sitúa, por tanto, en la integración del problema y en su formulación matemática aplicada al caso de València.

Desde el punto de vista matemático, los trabajos previos sobre planificación de rutas con criterios ambientales (como [10, 11]) utilizan principalmente pesos estáticos o promediados sobre grafos, sin incorporar predicción temporal. Los trabajos de predicción de calidad del aire basados en LSTM [12] modelan la evolución temporal pero no la integran en un problema de optimización de rutas. Los modelos generativos aplicados a contaminación [13] trabajan con datos espaciotemporales completos (tipo imagen) y no con redes de estaciones dispersas. La aportación diferencial de este TFG consiste, por tanto, en encadenar formalmente la interpolación IDW (Capítulo 4), la predicción LSTM (Capítulo 5), la generación GAN de escenarios de estrés (Capítulo 6) y el problema de caminos mínimos sobre un grafo ponderado por el funcional de exposición, dentro de un marco matemático unificado.

Capítulo 2

Datos y preprocesamiento

2.1 Descripción de los datos

Antes de presentar la estructura formal de los datos, conviene indicar con claridad su procedencia. El trabajo se apoya en ficheros JSON obtenidos a través del proyecto CITCOM.AI. Por tanto, aunque los conjuntos utilizados se encuadran en el ecosistema de datos urbanos de València, en este TFG no se han tomado directamente del Centro de Datos Abiertos del Ayuntamiento como fuente operativa principal, sino desde la infraestructura vinculada a dicho proyecto europeo. Éste se centra en el desarrollo y validación de soluciones de inteligencia artificial para ciudades inteligentes, por lo que resulta coherente con un estudio orientado a predicción ambiental y planificación de rutas sensibles a la contaminación [17]. A partir de esta procedencia se trabajó con series temporales georreferenciadas de calidad del aire y variables meteorológicas en distintas resoluciones temporales.
Desde el punto de vista sustantivo, los ficheros contienen tanto mediciones ambientales como metadatos espaciales y temporales. Entre las variables de calidad del aire aparecen, entre otras, las siguientes:

- dióxido de nitrógeno (NO_2),
- partículas en suspensión de diámetro inferior a $10\,\mu$m (PM_{10}),
- partículas finas de diámetro inferior a $2.5\,\mu$m ($PM_{2.5}$),
- ozono troposférico (O_3),
- dióxido de azufre (SO_2).

Junto a ellas se registran variables meteorológicas tales como temperatura, humedad relativa, velocidad y dirección del viento, presión atmosférica y precipitación. Esta descripción es importante porque las siglas anteriores se emplearán de forma reiterada en los capítulos posteriores; a partir de este punto se utilizarán ya de forma abreviada.
En cuanto a la cobertura temporal, se trabaja con datos de calidad del aire correspondientes a los años 2022, 2023 y 2024, y con datos meteorológicos de 2023 y 2024. El análisis exploratorio posterior mostrará además cuántas estaciones intervienen efectivamente en cada resolución temporal y qué diferencias de completitud presentan.

Análisis teórico

Desde el punto de vista del almacenamiento, los datos se presentan en formato *JSON* (*JavaScript Object Notation*). Un fichero JSON puede verse como una colección de documentos estructurados en forma de pares `clave: valor`, anidados en objetos y listas.
Cada documento describe una observación (por ejemplo, una medida de calidad del aire en una estación y una fecha), con campos como `entityId`, `timestamp`, `NO2`, `O3`, `temperature`, etc.

Este formato es propio de bases de datos no relacionales orientadas a documentos, donde cada registro puede tener una estructura parcialmente flexible (campos opcionales, subdocumentos, etc.), en contraste con el modelo relacional clásico, basado en tablas de estructura fija. Esta estructura es favorable para datos de contaminación, ya que permite almacenar los valores físicos y metadatos adicionales, además de facilitar su reutilización en scripts de carga y procesos automáticos de análisis.
Respecto a los datos, podemos modelizarlos de la siguiente forma:

$$\mathcal{D} = \{(t_i, s_i, x_i) : i = 1, \ldots, n\},$$

donde:

- t_i es un instante de tiempo (por ejemplo, en una escala discreta de intervalos de 60 minutos),
- s_i identifica una estación de medida (un punto en el espacio geográfico),
- $x_i \in \mathbb{R}^p$ es un vector de variables (contaminantes y/o variables meteorológicas) observadas en (t_i, s_i).

Cabe recordar que, en nuestro caso, tenemos dos conjuntos de datos distintos, sobre contaminantes y meteorológicos, que utilizaremos en el preprocesamiento para completar su adecuada limpieza y adecuación, debido a que disponemos de muestras discretas y con valores faltantes, por lo que el preprocesamiento persigue aproximarse a un conjunto de observaciones $\{x_i\}_{i=1}^n$ lo más coherente posible con dicho proceso. Posteriormente se tomará una decisión sobre el resultado de ese análisis. Respecto a la información subyacente en cada dataset, en calidad del aire, tenemos principalmente NO_2, PM_{10}, $PM_{2.5}$, O_3, SO_2, medidas en $\mu g/m^3$. Respecto a las variables meteorológicas, distinguimos temperatura, humedad relativa, velocidad y dirección del viento, presión atmosférica, precipitación, medidas en sus unidades físicas correspondientes.
En nuestro caso, cada Json tiene las observaciones de distintas estaciones de València. La estructura de dichos objetos son, para meteorología:

```
W03_VALENCIAAEROPUERTO_60m
Fecha                2023-12-14 08:00:00+00:00
Longitud             -0.47
Latitud              39.49
Altitud              55.9 m
Temperatura          12.8 C
Humedad              38 %
Velocidad de viento  4.3 m/s
Dirección de viento  210 deg
Precipitación        0 mm
Insolación           40
```

y para calidad del aire:

```
A01_AVFRANCIA_60m
Fecha        2023-01-01 00:00:00+00:00
Longitud     -0.3426602
Latitud      39.4575225
NO2          27 ug/m3
PM10         23 ug/m3
PM2.5        8 ug/m3
O3           28 ug/m3
SO2          4 ug/m3
Calidad      Razonablemente Buena
```

Para incluirlos, definimos dos scripts de carga:

- `cargar_aire_mejorado.py`, encargado de:
  (a) Leer los ficheros JSON de aire (10, 60 y 24 horas).
  (b) Parsear las fechas al tipo `datetime64`.
  (c) Extraer el identificador de estación (a partir de `entityId`) en una columna `estacion`.
  (d) Seleccionar y convertir a tipo numérico las columnas de contaminantes.
  (e) Generar indicadores booleanos `X_was_na` para cada variable X, que señalan si un valor ha sido imputado.
  (f) Filtrar rangos físicos básicos para descartar valores claramente aberrantes (por ejemplo, $\mathrm{PM}_{10} \in [0, 500]$).
  (g) Eliminar duplicados con la misma pareja (estación, fecha).
- `cargar_meteo_mejorado.py`, para mapear variables meteorológicas homogéneas, por ejemplo:

$$\begin{aligned}
\texttt{temperatureValue} &\mapsto \texttt{temperature}\ (\text{ºC}),\\
\texttt{relativeHumidityValue} &\mapsto \texttt{humidity}\ (\%),\\
\texttt{windSpeedValue} &\mapsto \texttt{wind_speed}\ (\text{km/h}),\\
\texttt{windDirectionValue} &\mapsto \texttt{wind_direction}\ (\text{º}),\\
\texttt{precipitationValue} &\mapsto \texttt{precipitation}\ (\text{l/m}^2).
\end{aligned}$$

Con lo cual obtenemos *dataframes* homogéneos (aire y meteo), con variables numéricas, sin duplicados y con coordenadas listas para análisis geoespacial, que constituyen la base para el análisis exploratorio y la imputación posterior.

2.2 Análisis exploratorio de los datos

Análisis teórico

El análisis exploratorio de los datos, también denominado en la literatura *Exploratory Data Analysis* (EDA), es un paso esencial en un proyecto de machine learning. Dicho proceso se caracteriza por la realización de un conjunto de operadores:

$$T_1, T_2, \ldots, T_k : \mathcal{D} \to \mathcal{R},$$

donde $\mathcal{R}$ representa diferentes resúmenes (estadísticos descriptivos, correlaciones, distribuciones, gráficos) que permiten:

- detectar problemas de calidad de datos (valores atípicos, huecos, errores),
- caracterizar distribuciones marginales y conjuntas,
- identificar patrones temporales (estacionalidad, tendencias),
- sugerir transformaciones o reducciones de dimensión.

El EDA se apoya en elementos de la estadística descriptiva, en concreto:

- Media, varianza, cuantiles, así como histogramas para aproximar densidades.

- Matrices de correlación, que recogen coeficientes $\rho_{X,Y} = \mathrm{corr}(X, Y)$.
- Gráficos temporales (series de medias horarias o mensuales) que permiten identificar componentes estacionales y patrones diarios.

Si $X^{(j)}$ denota la j-ésima variable (por ejemplo, NO_2), el EDA proporciona estimadores $\hat{\mu}_j$, $\hat{\sigma}_j$, $\widehat{\mathrm{corr}}(X^{(j)}, X^{(k)})$ y representaciones visuales que guían las decisiones de preprocesamiento posteriores.

Análisis aplicado

Aplicado a este proyecto, se ha desarrollado un script de EDA. Dicho script se ha utilizado para cada conjunto de datos (calidad del aire 10/60/24 min, meteorología 10/60 min) y realiza las siguientes tareas principales:

(a) **Cobertura y estaciones.** Para cada resolución se cuenta el número de estaciones únicas y el porcentaje de registros con estación no nula. En calidad del aire, se obtienen 11 estaciones únicas sin registros con estación faltante para las resoluciones de 10, 60 y 24 horas. En meteorología, la cobertura es menor (5 estaciones a 10 min y 3 a 60 min), lo que tendrá implicaciones en el análisis espacial posterior.

(b) **Estadísticas descriptivas.** Se calculan medias, desviaciones típicas, mínimos, máximos y cuantiles, así como conteos y porcentaje de valores nulos. Por ejemplo, para calidad del aire (60 min) se obtiene sobre todas las estaciones:

$$\mathbb{E}[\mathrm{NO_2}] \approx 24.7, \quad \mathbb{E}[\mathrm{PM_{10}}] \approx 47.9, \quad \mathbb{E}[\mathrm{PM_{2.5}}] \approx 29.1,$$

con colas largas en las distribuciones de PM_{10} y $PM_{2.5}$.

(c) **Distribuciones y atípicos.** Se construyen histogramas por variable, año y resolución para identificar valores atípicos y comparar la forma de las distribuciones entre años. Tal y como podemos observar en la Figura 2.1, las distribuciones de los contaminantes muestran colas largas hacia valores altos. PM_{10} y $PM_{2.5}$ presentan valores extremos que ya se habían acotado parcialmente mediante filtros físicos en la fase de carga.

(d) **Correlaciones.** Se calcula la matriz de correlación entre variables de calidad del aire, representada como mapa de calor (véase la Figura 2.2). Lo más apreciable es la alta correlación PM_{10}–$PM_{2.5}$ (coeficiente $r \approx 0.9$) y una correlación negativa moderada NO_2–O_3 ($r \approx -0.5$). El resto de pares presenta correlaciones en módulo inferiores a 0.3, lo que indica relaciones lineales débiles.

(e) **Tendencias temporales.** Se analizan gráficas de tendencia para NO_2 y otros contaminantes, tanto a escala anual como diaria. En particular, se han generado gráficos de la media horaria de NO_2 por año y estación. Un ejemplo representativo se muestra en la Figura 2.3, donde se observa la evolución media de NO_2 a lo largo del día, promediada sobre las estaciones urbanas receptoras de tráfico.

Cabe destacar que, en etapas tempranas, algunos filtros sobre valores extremos reducían de forma excesiva el número de estaciones disponibles. Por este motivo se optó por relajar dichos filtros para maximizar la cobertura espacial, asumiendo la presencia de algunos valores más extremos que se controlan en fases posteriores del modelado.

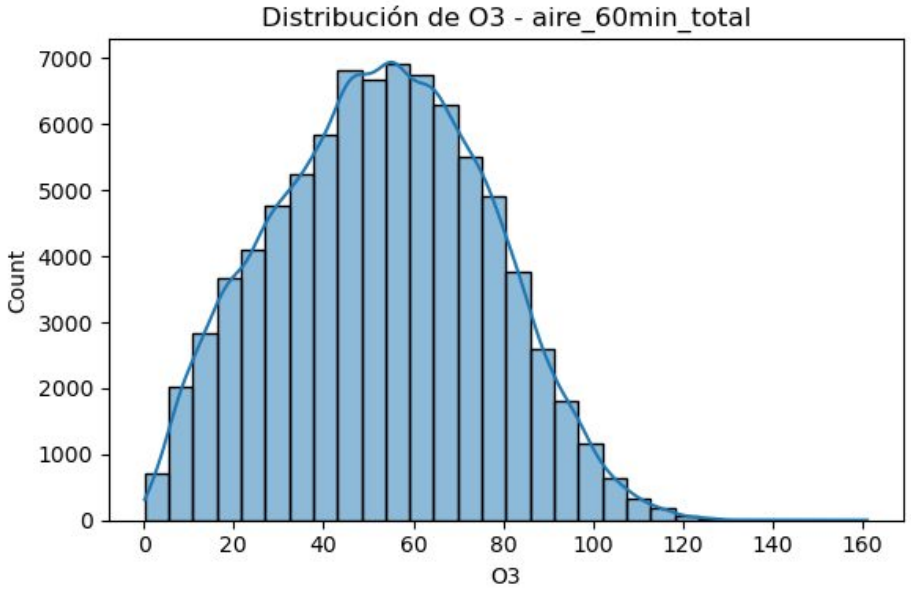


Figura 2.1: Distribución del ozono troposférico (O_3) considerando todas las estaciones y años en la resolución de 60 minutos. La distribución es unimodal y presenta una cola derecha apreciable, lo que indica la presencia de episodios con concentraciones relativamente altas.

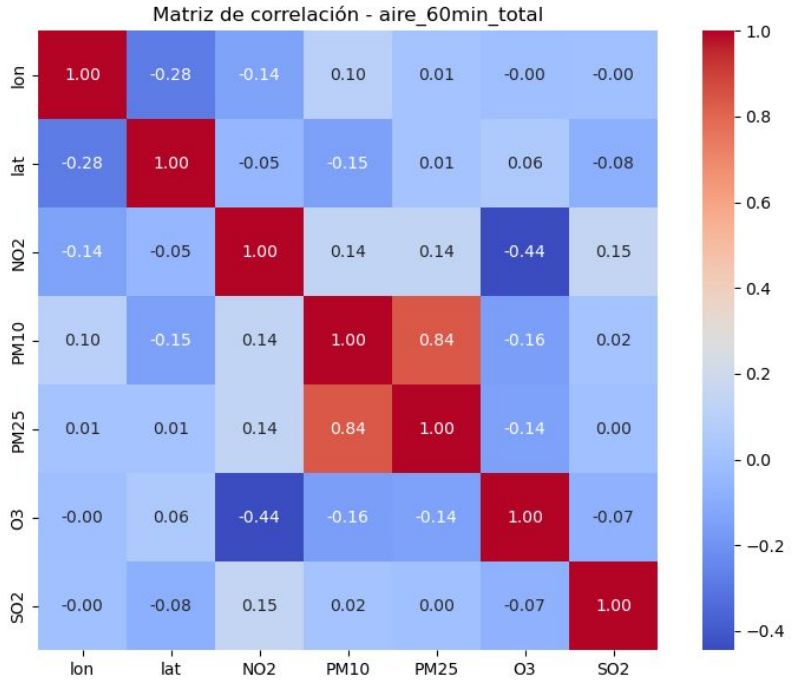


Figura 2.2: Matriz de correlación para las variables de calidad del aire en la resolución de 60 minutos. Destaca la asociación positiva entre PM_{10} y $PM_{2.5}$, así como la relación negativa moderada entre NO_2 y O_3.

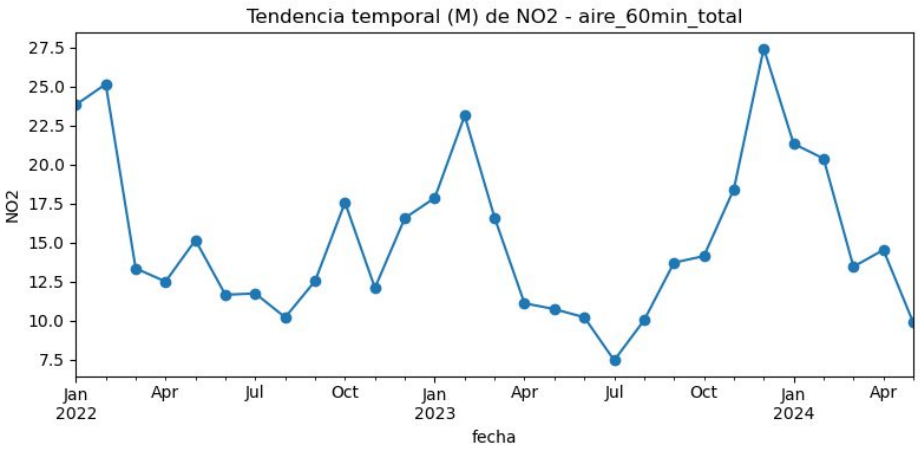


Figura 2.3: Evolución mensual media del dióxido de nitrógeno (NO_2) para el conjunto agregado de estaciones en la resolución de 60 minutos. La figura permite comparar la variabilidad estacional entre los distintos años del periodo estudiado.

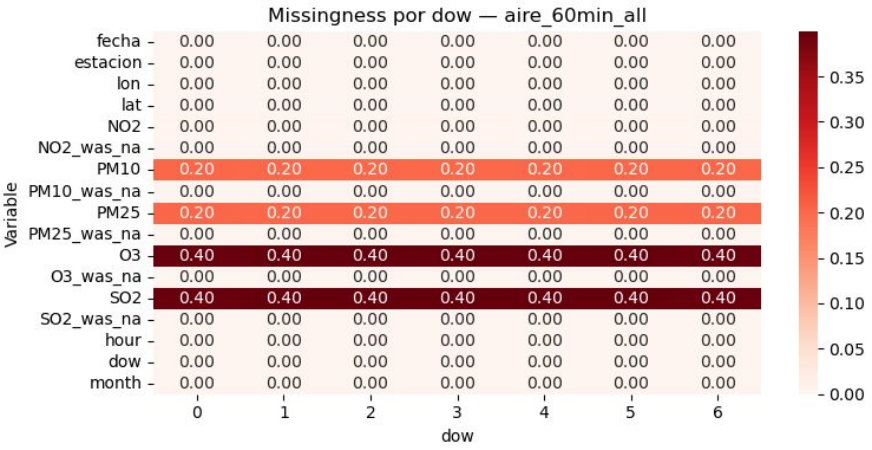


Figura 2.4: Mapa de calor del porcentaje de valores faltantes por variable y día de la semana (*dow*, *day of week*) en la resolución de 60 minutos. La intensidad del color refleja la fracción de ausencias, y se observa que las variables O_3 y SO_2 presentan un patrón de missingness claramente superior al de NO_2.

2.3 Valores faltantes y tipos de *missingness*

Análisis teórico

En primer lugar, definimos formalmente el concepto de valor faltante, lo que nos permitirá distinguir los tipos correspondientes.

Definición 2.3.1. *Sea X una variable aleatoria (por ejemplo, la concentración de NO_2 en cierta estación) y sea R una variable indicadora tal que $R = 1$ si X se observa y $R = 0$ si X es faltante. Decimos que:*

- *La falta de datos es* MCAR *(*Missing Completely At Random*) si la distribución de R es inde-*

pendiente de X y de cualquier otra variable observada o no observada, es decir,

$$\mathbb{P}(R = 0 \mid X, Z) = \mathbb{P}(R = 0)$$

para toda colección de variables Z.

- *La falta de datos es* MAR *(*Missing At Random*) si la probabilidad de ausencia depende únicamente de otras variables observadas Z, pero no del valor faltante en sí; formalmente,*

$$\mathbb{P}(R = 0 \mid X, Z) = \mathbb{P}(R = 0 \mid Z).$$

- *La falta de datos es* MNAR *(*Missing Not At Random*) si $\mathbb{P}(R = 0)$ depende del valor faltante de X u otra información no observada, de modo que ni eliminar ni imputar con métodos estándar elimina el sesgo.*

Distinguir entre estos tipos de missingness es un paso crucial para seleccionar correctamente el método de imputación adecuado. En el caso de MCAR, los registros con valores faltantes son una muestra representativa y la imputación simple o la eliminación de casos no introduce sesgo. En el caso de MAR, es posible obtener imputaciones imparciales aprovechando las relaciones con otras variables observadas. Sin embargo, en MNAR, cualquier imputación basada sólo en datos observados arrastra un sesgo estructural difícil de corregir.

Análisis aplicado

Para analizar los datos faltantes del dataset, se han seguido los siguientes pasos:

(a) Se unificaron todos los años disponibles (aire 2022–2024; meteo 2023–2024) en ambos *dataframes*.

(b) Se calculó la fracción de valores faltantes (porcentaje de NaN) por variable y por estación.

(c) Se añadieron variables temporales derivadas: hora del día (`hour`), día de la semana (`dow`) y mes del año (`month`).

(d) Se construyeron *heatmaps* en los que el eje y corresponde a las variables y el eje x a categorías temporales (hora, día, mes), coloreando cada celda según la fracción de valores faltantes.

En consecuencia, se pueden extraer estos resultados para calidad de aire:

- PM_{10} y $PM_{2.5}$ presentan alrededor de un 20% de valores faltantes, centrados en estaciones específicas.
- O_3 y SO_2 presentan alrededor de un 40% de valores faltantes, centrados también en estaciones concretas.
- NO_2 es prácticamente completo (sin NaN).

Del mismo modo, para meteorología:

- Temperatura y humedad muestran entre un 1 y un 3% de valores faltantes.
- Precipitación, velocidad y dirección del viento presentan proporciones de faltantes inferiores al 1%.

Adjuntando y analizando los *heatmaps* y la variación de la missingness en función de las variables temporales y de la estación sugiere el siguiente diagnóstico:

- La proporción de NaN es aproximadamente constante a lo largo del día y de la semana, sin picos nocturnos ni de fin de semana que apunten a problemas de adquisición sistemáticos en determinados horarios.
- Existe heterogeneidad entre estaciones (unas acumulan más huecos que otras).
- No se observa concentración de huecos en rangos extremos de las distribuciones, lo que sugiere que la probabilidad de falta no depende del valor verdadero del contaminante o variable meteorológica.

Este comportamiento nos lleva a un mecanismo MAR: la probabilidad de que un dato esté ausente parece depender de variables observables (mes, estación, condiciones operativas) y no del valor faltante en sí. Ello justifica el uso de métodos de imputación que explotan relaciones entre variables y patrones temporales.

2.4 Imputación de valores faltantes

Análisis teórico

Una estrategia de imputación puede definirse como un operador que toma un conjunto de datos con huecos y devuelve un conjunto en el que se ha definido un valor para cada observación faltante. En la práctica, tenemos diferentes métodos de imputación:

- **Imputación local univariante.** Técnicas como *forward-fill* (ffill) y *backward-fill* (bfill) explotan la estructura temporal de una serie $\{X_t\}$, reemplazando un hueco corto por el valor anterior o posterior. Esta idea es razonable cuando se supone que la serie es suficientemente regular en escalas pequeñas de tiempo.
- **Interpolación.** Para huecos de longitud moderada, se puede aproximar linealmente o mediante interpolación polinómica el valor faltante como combinación de observaciones vecinas:

$$X_t \approx \lambda X_{t_1} + (1-\lambda) X_{t_2}, \quad t_1 < t < t_2.$$

- **Imputación multivariante.** Métodos como *IterativeImputer* o *KNNImputer* consideran simultáneamente varias variables correlacionadas. Por ejemplo, *IterativeImputer* construye un modelo de regresión para cada variable con huecos, usando el resto como predictores, y actualiza iterativamente las imputaciones hasta la convergencia.
- **Imputación espacial.** Cuando existen varias estaciones con diferente grado de missingness, es posible explotar la proximidad espacial: un KNNImputer "espacial" aproxima el valor faltante en una estación a partir de valores en estaciones cercanas en el espacio.

Es posible combinar en un *pipeline* que distinga entre *huecos cortos* (tratados localmente) y *huecos largos* (tratados con modelos multivariantes o espaciales). La biblioteca `scikit-learn` proporciona herramientas como `ColumnTransformer` y `Pipeline` que permiten componer estas transformaciones de forma modular (véase, por ejemplo, Raschka et al., 2022).

Análisis aplicado

Una vez diagnosticado MAR, podemos utilizar técnicas que utilicen variables correlacionadas para los huecos largos de datos faltantes. Por ello la estrategia se dividirá en dos partes:

(a) **Imputación local de huecos cortos.** Se aplicó un relleno hacia adelante y hacia atrás limitado a un paso de 60 minutos (ffill/bfill con `limit=1`), cubriendo huecos de un solo intervalo consecutivo.

(b) **Imputación multivariante de huecos largos.** Para los huecos que persistían tras la fase anterior, se utilizó `IterativeImputer` de `scikit-learn` con `max_iter = 10` y `random_state = 0`, explotando las correlaciones entre contaminantes y entre variables meteorológicas.

El resultado de este proceso puede resumirse en la Tabla 2.1, que recoge el número de valores faltantes antes y después de la imputación:

Cuadro 2.1: Recuento de valores faltantes antes y después de la imputación (60 min).

Variable	Nulos antes	Nulos después
NO_2	674	0
PM_{10}	41855	0
$PM_{2.5}$	41860	0
O_3	82948	0
SO_2	82948	0
Temperatura	173	0
Humedad	173	0
Vel. viento	6	0
Dir. viento	4	0
Presión	0	0
Precipitación	16	0

Finalmente, para valorar la calidad de la imputación, realizamos un *masking test*, consistente en:

(a) Enmascarar aleatoriamente un pequeño porcentaje (en este caso un 5%) de valores reales por variable.

(b) Aplicar el pipeline de imputación sobre este conjunto con huecos artificiales.

(c) Comparar los valores imputados $\hat{x}_i$ con los valores reales x_i, mediante el error medio absoluto (MAE) y el error cuadrático medio (MSE):

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|\hat{x}_i - x_i|, \quad \mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(\hat{x}_i - x_i)^2.$$

En la siguiente tabla se observa que los errores obtenidos son inferiores a 0.2 unidades (normalizadas) en todas las variables, lo que sugiere una imputación coherente con las distribuciones originales.

Cuadro 2.2: Resultados del *masking test*: MAE y MSE de las variables tras la imputación, en unidades normalizadas.

Variable	MAE (u. normal.)	MSE (u. normal.)
Temperatura	0.12	0.02
Humedad	0.15	0.03
Vel. viento	0.10	0.01
Presión	0.08	0.01
Precipitación	0.18	0.04
NO_2	0.05	0.00
PM_{10}	0.07	0.01
$PM_{2.5}$	0.06	0.01
O_3	0.09	0.02
SO_2	0.04	0.00

2.5 Escalado de variables

Análisis teórico

El escalado de variables es una transformación

$$S : \mathbb{R}^p \to \mathbb{R}^p$$

que busca homogeneizar la magnitud de las características antes de entrenar un modelo de aprendizaje automático. Dos estrategias habituales (ver, por ejemplo, Raschka et al. [1, cap. 4, pp. 120–121]) son:

Definición 2.5.1. *Dado un vector de observaciones $\{x_i\}_{i=1}^n$ de una variable escalar X, definimos el* escalado estándar *(*StandardScaler*) como la transformación*

$$z_i = \frac{x_i - \hat{\mu}}{\hat{\sigma}},$$

donde $\hat{\mu}$ y $\hat{\sigma}$ son la media y desviación típica muestrales.

Definición 2.5.2. *Definimos el* escalado min–max *(*MinMaxScaler*) de $\{x_i\}$ en un intervalo $[a, b]$ como*

$$z_i = a + (b - a)\,\frac{x_i - x_{\min}}{x_{\max} - x_{\min}},$$

donde $x_{\min}$ y $x_{\max}$ son el mínimo y máximo de la muestra.

Es decir, el escalado estándar traslada los datos para que queden centrados en torno a cero ($\hat{\mu}_z \approx 0$) y los reescala para que la varianza sea aproximadamente uno ($\hat{\sigma}_z \approx 1$). Como consecuencia, distintas variables que originalmente tienen unidades y órdenes de magnitud distintos pasan a tener varianzas comparables. Esto es especialmente conveniente en modelos que suponen explícita o implícitamente que las características de entrada están centradas y tienen una escala similar.
A su vez, en el escalado min–max (*MinMaxScaler*) se eligen a y b de forma que el intervalo observado $[x_{\min}, x_{\max}]$ se mapea linealmente en un intervalo fijado $[c, d]$, típicamente $[0, 1]$ o $[-1, 1]$. Este control del rango de entrada es útil en modelos cuya respuesta depende de forma sensible del intervalo en el que caen las entradas.

Análisis aplicado

Después de completar la imputación, el siguiente paso ha sido homogeneizar la escala de las variables para facilitar la convergencia y la comparabilidad en los modelos posteriores. Se han aplicado dos estrategias de escalado según el tipo de variable:

- **Contaminantes (NO_2, PM_{10}, $PM_{2.5}$, O_3, SO_2):** se aplica `StandardScaler`, que centra cada variable en media cero y desviación estándar uno.
- **Meteorología (temperatura, humedad, velocidad y dirección de viento, presión, precipitación):** se aplica `MinMaxScaler`, que reescala cada variable al intervalo $[0, 1]$.

Los cuadros siguientes resumen los principales estadísticos de las variables una vez escaladas:

Cuadro 2.3: Resumen estadístico de los contaminantes tras `StandardScaler`.

Variable	Media	Desv. típica	Mínimo	Máximo
NO_2	0.00	1.00	-2.1	2.5
PM_{10}	0.00	1.00	-1.8	3.0
$PM_{2.5}$	0.00	1.00	-2.0	2.8
O_3	0.00	1.00	-1.5	2.3
SO_2	0.00	1.00	-1.6	2.4

Cuadro 2.4: Resumen estadístico de las variables meteorológicas tras `MinMaxScaler`.

Variable	Mínimo	Mediana	Media	Máximo
Temperatura	0.00	0.52	0.50	1.00
Humedad	0.00	0.45	0.48	1.00
Vel. viento	0.00	0.30	0.35	1.00
Dir. viento	0.00	0.45	0.50	1.00
Presión	0.00	0.55	0.54	1.00
Precipitación	0.00	0.00	0.05	1.00

Estos resultados son coherentes con las definiciones de los escalados: en los contaminantes, cada variable queda centrada y con desviación unitaria, mientras que las variables meteorológicas quedan contenidas en el intervalo $[0, 1]$, preservando el orden de los valores originales.

2.6 Síntesis del preprocesamiento y elección operativa del dióxido de nitrógeno

Recapitulando, en el Capítulo 1 se ha motivado, desde el punto de vista de la salud pública y de las políticas de calidad del aire, la decisión de centrar este Trabajo Fin de Grado en el dióxido de nitrógeno (NO_2) como contaminante objetivo. A continuación se recapitulan las conclusiones del preprocesamiento que refuerzan esta elección desde el punto de vista estrictamente empírico.
En primer lugar, el análisis exploratorio y de valores faltantes realizado en este capítulo muestra una diferencia clara entre la calidad de las series de NO_2 y la del resto de contaminantes:

- NO_2 presenta una cobertura temporal prácticamente completa, con una fracción de valores ausentes muy reducida y homogénea entre estaciones.
- PM_{10} y $PM_{2.5}$ presentan en torno a un 20% de valores faltantes, con huecos de longitud variable y cierta heterogeneidad entre años y estaciones.

- O_3 y SO_2 alcanzan proporciones de valores ausentes próximas al 40%, como se observa en los mapas de calor de missingness por día de la semana y por mes, donde las filas correspondientes a `O3_was_na` y `SO2_was_na` aparecen sistemáticamente con valores elevados.

Aunque el pipeline de imputación diseñado en este capítulo (basado en relleno local de huecos cortos y *IterativeImputer* multivariante para huecos largos) permite construir versiones imputadas de todas las variables, la cantidad de información realmente observada difiere de forma notable entre contaminantes. En particular, entrenar modelos de aprendizaje profundo de alta capacidad, como las redes de memoria a largo plazo (LSTM) y las redes generativas adversarias (GAN) sobre variables con un 20–40% de valores originalmente ausentes exigiría una dependencia muy fuerte de las imputaciones, con el consiguiente riesgo de introducir patrones y comportamientos temporales que no concuerdan con los datos reales. Además, estos valores ausentes se centran en estaciones específicas, empeorando así la calidad del mapeado resultante de estos contaminantes.
Por el contrario, en el caso de NO_2 la imputación actúa esencialmente como un ajuste fino sobre una serie ya de por sí densa, garantizando que las ventanas temporales utilizadas en los modelos secuenciales contienen mayoritariamente observaciones directas. Además, las gráficas de tendencias y las distribuciones marginales de NO_2 muestran un comportamiento razonablemente estable entre años, lo que facilita la construcción de conjuntos de entrenamiento, validación y prueba que representen bien la variabilidad temporal.
A la vista de estos resultados, y sin perjuicio de que el pipeline de preprocesamiento general pueda utilizarse en trabajos futuros para construir modelos multivariantes que incorporen PM_{10}, $PM_{2.5}$, O_3 y SO_2, en este TFG se adopta la siguiente decisión:

> *En los capítulos de modelado profundo, centrados en redes de memoria a largo plazo (LSTM) y redes generativas adversarias (GAN), y en los de planificación de rutas, se trabajará con un conjunto de datos canónico centrado en NO_2, a resolución de 10 minutos para la etapa de modelado temporal y rutas, obtenido a partir del pipeline de carga, imputación y escalado descrito en este capítulo.*

De este modo, el Capítulo 2 cierra la fase de preprocesamiento con un conjunto de datos específico y bien caracterizado sobre el que se apoyan los desarrollos matemáticos y computacionales de los capítulos siguientes: por un lado, el modelo espacial de interpolación por ponderación inversa de la distancia (Capítulo 4) y la definición del funcional de exposición; por otro, los modelos secuenciales de memoria a largo plazo (LSTM) del Capítulo 5 y el modelo generativo basado en redes generativas adversarias (GAN) del Capítulo 6.

Capítulo 3

Fundamentos matemáticos del aprendizaje profundo

En este capítulo se introducen los conceptos matemáticos básicos necesarios para entender los modelos de aprendizaje profundo que se utilizarán en este Trabajo Fin de Grado. No se pretende reproducir toda la información acerca de los conceptos utilizados, sino definir un marco teórico donde poder trabajar, fijando así un lenguaje y notación coherentes sobre los que formular los modelos específicos (interpolación por ponderación inversa de la distancia, redes de memoria a largo plazo y redes generativas adversarias) que aparecerán en capítulos posteriores.
Siguiendo la estructura de la memoria, cada sección se divide en dos partes: un análisis teórico y un análisis aplicado, en el que se interpreta cómo se concretan estos conceptos en el problema de predicción de NO_2 y planificación de rutas de mínima exposición en la ciudad de València.

3.1 Problema de aprendizaje supervisado y riesgo de generalización

Análisis teórico

El trabajo se centra en el caso de aprendizaje supervisado, donde se distinguen los siguientes elementos:

- Una colección de *entradas* que describen cada ejemplo (por ejemplo, una ventana temporal de mediciones de NO_2 en una estación).
- Una *salida* asociada a cada ejemplo (por ejemplo, el valor futuro de NO_2 que queremos predecir).
- Un *modelo* que, dada una entrada, produce una predicción de la salida.
- Una forma de medir el *error* de las predicciones.

El objetivo no se reduce únicamente a crear un modelo que sólo funcione bien en los datos disponibles, sino que también produzca buenas predicciones sobre datos nuevos.

Definición 3.1.1. *Formalmente, sea $\mathcal{X}$ un espacio de entrada y $\mathcal{Y}$ un espacio de salida. Se supone que existe una distribución de probabilidad desconocida P sobre el producto $\mathcal{X} \times \mathcal{Y}$, que representa el mecanismo mediante el cual, en el mundo real, se generan pares de datos (x, y). Se observa una muestra finita*

$$\mathcal{D}_n = \{(x_i, y_i)\}_{i=1}^n,$$

donde cada par (x_i, y_i) se ha generado de manera independiente según P.

Un modelo de aprendizaje supervisado *consiste en elegir una familia de funciones*

$$\{f_\theta : \mathcal{X} \to \mathcal{Y} \mid \theta \in \Theta\},$$

donde θ es un vector de parámetros (por ejemplo, los pesos de una red neuronal), junto con una función de pérdida

$$\ell : \mathcal{Y} \times \mathcal{Y} \to [0, +\infty)$$

que mide el error cometido al predecir $\hat{y} = f_\theta(x)$ cuando el valor real es y.

El comportamiento ideal del modelo se mide mediante el *riesgo esperado* o *riesgo de generalización*:

$$\mathcal{R}(\theta) \;=\; \mathbb{E}_{(x,y)\sim P}\big[\, \ell\big(y, f_\theta(x)\big) \,\big],$$

que representa la pérdida media que tendría el modelo si se probara en todos los datos posibles generados por la distribución real P.
Como P es desconocida, no podemos calcular $\mathcal{R}(\theta)$ exactamente. En su lugar, utilizamos el *riesgo empírico* calculado sobre la muestra observada:

Definición 3.1.2. *El* riesgo empírico *asociado a una muestra $\mathcal{D}_n = \{(x_i, y_i)\}_{i=1}^n$ se define como*

$$\hat{\mathcal{R}}_n(\theta) \;=\; \frac{1}{n}\sum_{i=1}^{n} \ell\big(y_i, f_\theta(x_i)\big).$$

El principio de minimización del riesgo empírico *consiste en elegir un vector de parámetros $\hat{\theta}_n \in \Theta$ que minimice esta cantidad, es decir,*

$$\hat{\theta}_n \in \arg\min_{\theta\in\Theta} \hat{\mathcal{R}}_n(\theta).$$

El problema fundamental del aprendizaje automático es que un modelo que minimiza muy bien el riesgo empírico $\hat{\mathcal{R}}_n(\theta)$ puede no minimizar el riesgo esperado $\mathcal{R}(\theta)$. Es decir, puede *ajustar demasiado* la muestra disponible (incluyendo su ruido) y comportarse mal en datos nuevos. A este fenómeno se le denomina *sobreajuste*. Si, por el contrario, el modelo es demasiado sencillo como para capturar la estructura de los datos, se habla de *infraajuste*.
La teoría de aprendizaje estadístico estudia cómo se relacionan, para distintos modelos y tamaños muestrales, el riesgo empírico y el riesgo esperado, y qué mecanismos (como la regularización) permiten controlar el sobreajuste [2, cap. 5, pp. 107–110].

Análisis aplicado

Dentro del contexto de este TFG, hallamos dos problemas de aprendizaje supervisado:

(a) **Predicción de NO_2 con redes de memoria a largo plazo (LSTM).** Para cada estación s se considera la serie temporal de NO_2. Para evitar confusión entre una observación individual y una ventana completa de entrada, denotamos por

$$u_t^{(s)} = \mathrm{NO2}_s(t)$$

el valor escalar observado en la estación s en el instante t. A partir de esa serie se construyen ventanas temporales de longitud fija L:

$$X_t^{(s)} = \big(u_{t-L+1}^{(s)}, \ldots, u_t^{(s)}\big) \in \mathbb{R}^L,$$

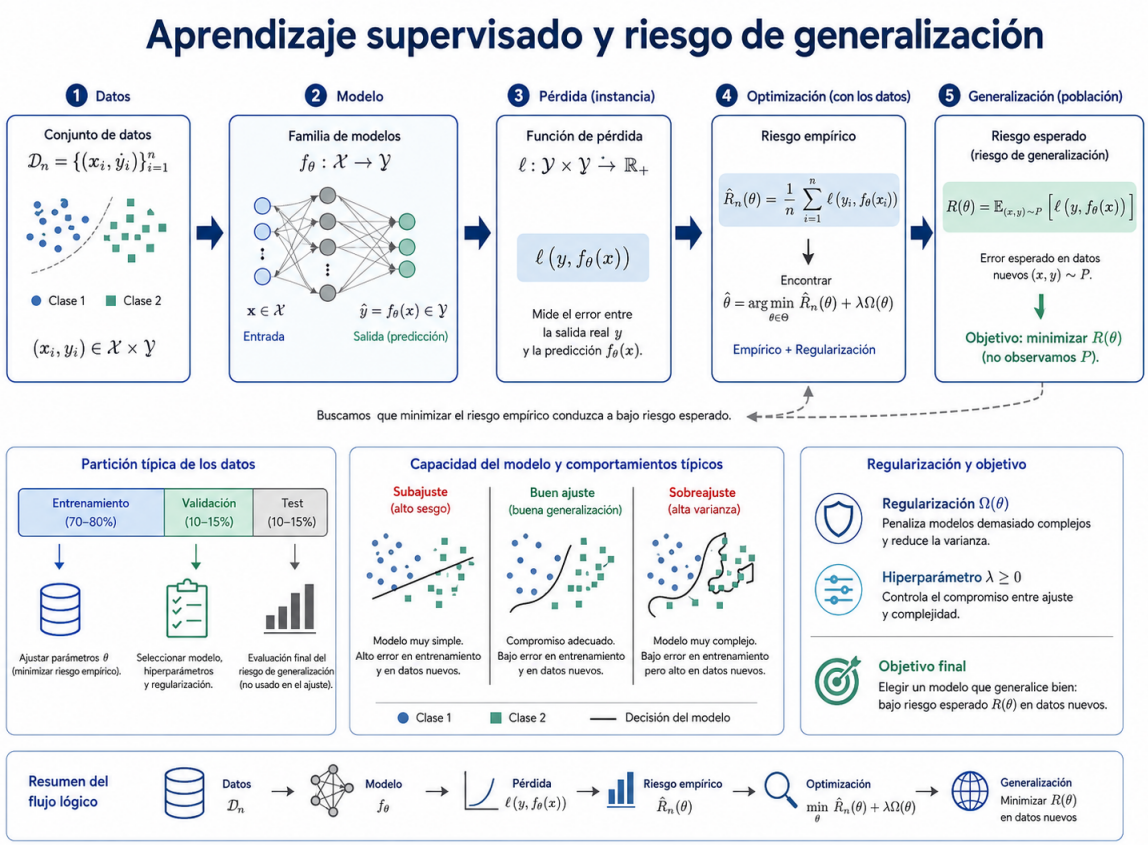


Figura 3.1: Relación entre aprendizaje supervisado, función de pérdida, riesgo empírico y riesgo esperado. El esquema resume la diferencia entre ajustar un modelo a los datos observados y obtener una solución que generalice correctamente a datos no vistos.

y se toma como salida

$$y_t^{(s)} = u_{t+\tau}^{(s)},$$

donde L es el *lookback* y τ el horizonte de predicción (por ejemplo, 60 minutos). El espacio de entrada es $\mathcal{X} = \mathbb{R}^L$ y el espacio de salida $\mathcal{Y} = \mathbb{R}$.

La función de pérdida elegida es el error cuadrático medio (MSE)

$$\ell(y, \hat{y}) = (y - \hat{y})^2,$$

de modo que el riesgo empírico coincide con el MSE sobre las ventanas de entrenamiento. El modelo f_θ será una red LSTM que se entrenará minimizando esta pérdida.

(b) **Generación de mapas de NO_2 con una red generativa adversaria condicional (GAN).** En el capítulo dedicado a las GAN se considera un modelo generativo en el que el generador toma como entrada un vector de ruido z (variable latente) y un vector de condicionamiento c (por ejemplo, información temporal), y produce como salida un vector en $\mathbb{R}^d$ que representa un escenario de NO_2 compatible con los datos observados. El discriminador recibe tanto muestras reales como generadas, junto con el mismo condicionamiento c, y aprende a distinguirlas.

Conviene señalar que una GAN no es un modelo supervisado estándar en el mismo sentido que la regresión LSTM. El discriminador sí resuelve una tarea binaria auxiliar, distinguir muestras reales de muestras generadas, pero el modelo completo se entrena como un juego adversario: el generador aprende a producir escenarios plausibles y el discriminador aprende a detectar si una muestra procede de los datos reales o del generador.

3.2 Redes neuronales como funciones paramétricas

Una vez fijado el marco general, describimos cómo se modelan matemáticamente las redes neuronales, comenzando por las redes *feedforward* o perceptrones multicapa, que son la base de las arquitecturas utilizadas posteriormente (LSTM y redes generativas adversarias).

Capas lineales y funciones de activación

Sea $d_0 \in \mathbb{N}$ la dimensión del espacio de entrada y sea $x \in \mathbb{R}^{d_0}$ un vector de características. La idea más simple para transformar x es aplicar una transformación afín, es decir, una transformación lineal seguida de un desplazamiento:

$$z = Wx + b,$$

donde $W \in \mathbb{R}^{d_1 \times d_0}$ es una matriz de pesos y $b \in \mathbb{R}^{d_1}$ es un vector de sesgos. En aprendizaje profundo esta operación suele denominarse *capa lineal*, aunque matemáticamente es una *capa afín* por la presencia del término de sesgo b.
Si sólo encadenásemos transformaciones afines, cualquier composición seguiría siendo afín y no se podrían modelar relaciones no lineales entre las variables. Por ello se introduce una función de activación no lineal $\sigma : \mathbb{R} \to \mathbb{R}$, que se aplica componente a componente:

$$h = \sigma(z), \qquad h_j = \sigma(z_j), \quad j = 1, \ldots, d_1.$$

Combinando ambas ideas, una *capa oculta* típica aplica primero una transformación afín y luego una activación:

$$h = \sigma(Wx + b).$$

Entre las funciones de activación más utilizadas destacan:

- la función ReLU, definida por $\sigma(x) = \max\{0, x\}$;

- la función sigmoide logística;
- la tangente hiperbólica.

Cada elección tiene implicaciones sobre el comportamiento del modelo y del entrenamiento [2, cap. 6, p. 168].

Redes *feedforward* o perceptrones multicapa

Una red neuronal *feedforward* se obtiene encadenando varias capas del tipo anterior. Se fija un número de capas ocultas $L \in \mathbb{N}$ y dimensiones

$$d_0, d_1, \ldots, d_L, d_{L+1},$$

donde d_0 es la dimensión de la entrada y d_{L+1} la de la salida. La red se define de forma recursiva:

$$\begin{aligned} h^{(0)} &= x \in \mathbb{R}^{d_0}, \\ h^{(\ell)} &= \sigma^{(\ell)}\big(W^{(\ell)} h^{(\ell-1)} + b^{(\ell)}\big), \quad \ell = 1, \ldots, L, \\ f_\theta(x) &= W^{(L+1)} h^{(L)} + b^{(L+1)}, \end{aligned}$$

donde $W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ y $b^{(\ell)} \in \mathbb{R}^{d_\ell}$ son los pesos y sesgos de la capa ℓ, y $\sigma^{(\ell)}$ son funciones de activación (que pueden ser todas iguales o distintas). El conjunto de parámetros de la red es

$$\theta = \big\{W^{(\ell)}, b^{(\ell)}\big\}_{\ell=1}^{L+1}.$$

En el caso de regresión, como la predicción es un valor real, es habitual que la capa de salida sea lineal (sin activación). En clasificación binaria o multiclase se suele añadir una activación sigmoide.
La composición de capas lineales y funciones de activación hace que la familia de funciones $x \mapsto f_\theta(x)$ sea muy flexible. De hecho, bajo ciertas condiciones, redes con un número suficiente de neuronas pueden aproximar cualquier función continua en un conjunto compacto con un error arbitrariamente pequeño, resultado conocido como *teorema de aproximación universal* [2, secc. 6.4.1, p. 193].

Ejemplos en el contexto de este trabajo

En este trabajo utilizamos la teoría anterior de la siguiente forma:

- **Redes LSTM**, que se pueden ver como una generalización de las redes anteriores al caso en que la entrada no es un único vector, sino una secuencia $(x_1, \ldots, x_T)$. Internamente, la red LSTM combina transformaciones afines y funciones de activación con compuertas que controlan qué información se mantiene en una memoria interna y cuál se olvida. A efectos del marco supervisado, una red LSTM define una función $f_\theta : \mathbb{R}^L \to \mathbb{R}$ que asigna a cada ventana de NO_2 una predicción futura.
- **Red generadora y discriminadora de la GAN**. El generador implementa un mapa

  $$G_\theta : \mathcal{Z} \times \mathcal{C} \to \mathbb{R}^d,$$

  donde $\mathcal{Z}$ es el espacio latente (ruido) y $\mathcal{C}$ el espacio de condicionamiento (información adicional, como la hora del día). El discriminador implementa un mapa

  $$D_\phi : \mathbb{R}^d \times \mathcal{C} \to (0, 1),$$

  que devuelve una puntuación interpretada como "probabilidad" de que un mapa de NO_2 sea real. En ambos casos, las redes se construyen como composiciones de capas lineales y activaciones, siguiendo el esquema anterior.

3.3 Entrenamiento mediante gradiente y retropropagación

Dado un modelo f_θ y una función de pérdida ℓ, el problema de entrenamiento consiste en encontrar un vector de parámetros $\theta \in \Theta \subset \mathbb{R}^p$ que minimice la pérdida media en la muestra, es decir, el riesgo empírico

$$\hat{\mathcal{R}}_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell\big(y_i, f_\theta(x_i)\big).$$

En redes neuronales, donde el número de parámetros puede ser muy grande, se utilizan métodos de optimización basados en gradientes.

Descenso de gradiente y variantes estocásticas

La idea básica del *descenso de gradiente* es partir de un valor inicial θ_0 e ir actualizando los parámetros en la dirección opuesta al gradiente del riesgo empírico:

$$\theta_{k+1} = \theta_k - \eta_k \, \nabla_\theta \hat{\mathcal{R}}_n(\theta_k),$$

donde $\eta_k > 0$ es la *tasa de aprendizaje* en la iteración k.
Cuando el número de ejemplos n es grande, calcular el gradiente sobre toda la muestra en cada iteración resulta costoso. Por ello se usan variantes *estocásticas*, en las que se reemplaza el gradiente completo por un gradiente aproximado calculado sobre un subconjunto B_k de índices, llamado *mini-batch*:

$$\theta_{k+1} = \theta_k - \eta_k \, \nabla_\theta \left(\frac{1}{|B_k|} \sum_{i \in B_k} \ell\big(y_i, f_{\theta_k}(x_i)\big) \right).$$

Este esquema se conoce como *descenso de gradiente estocástico* (SGD). Sobre él se construyen optimizadores más avanzados, como Adam o RMSProp, que ajustan de forma adaptativa la magnitud de los pasos y acumulan información sobre los gradientes para mejorar la estabilidad del entrenamiento [2, 1].

Retropropagación del error

El cálculo directo del gradiente $\nabla_\theta \hat{\mathcal{R}}_n(\theta)$ sería ineficiente si se derivara cada parámetro de forma independiente. La *retropropagación del error* (*backpropagation*) resuelve este problema aplicando la regla de la cadena de manera ordenada sobre la composición de capas de la red.
Para fijar la notación, consideremos una red con activaciones

$$z^{(\ell)} = W^{(\ell)} h^{(\ell-1)} + b^{(\ell)}, \qquad h^{(\ell)} = \sigma^{(\ell)}\big(z^{(\ell)}\big), \qquad \ell = 1, \dots, L,$$

con $h^{(0)} = x$, y una pérdida final $\ell(y, f_\theta(x))$. El procedimiento puede resumirse en tres pasos:

(a) **Propagación hacia delante (*forward*).** Se calcula la salida de la red almacenando las cantidades intermedias

$$z^{(1)}, h^{(1)}, \dots, z^{(L)}, h^{(L)}, f_\theta(x).$$

Estas cantidades se conservan porque son necesarias para aplicar después la regla de la cadena.

(b) **Cálculo del error en la salida.** Se calcula la derivada de la pérdida respecto a la salida del modelo. En regresión con error cuadrático, por ejemplo, si $\ell(y, \hat{y}) = (y - \hat{y})^2$, entonces

$$\frac{\partial \ell}{\partial \hat{y}} = 2(\hat{y} - y).$$

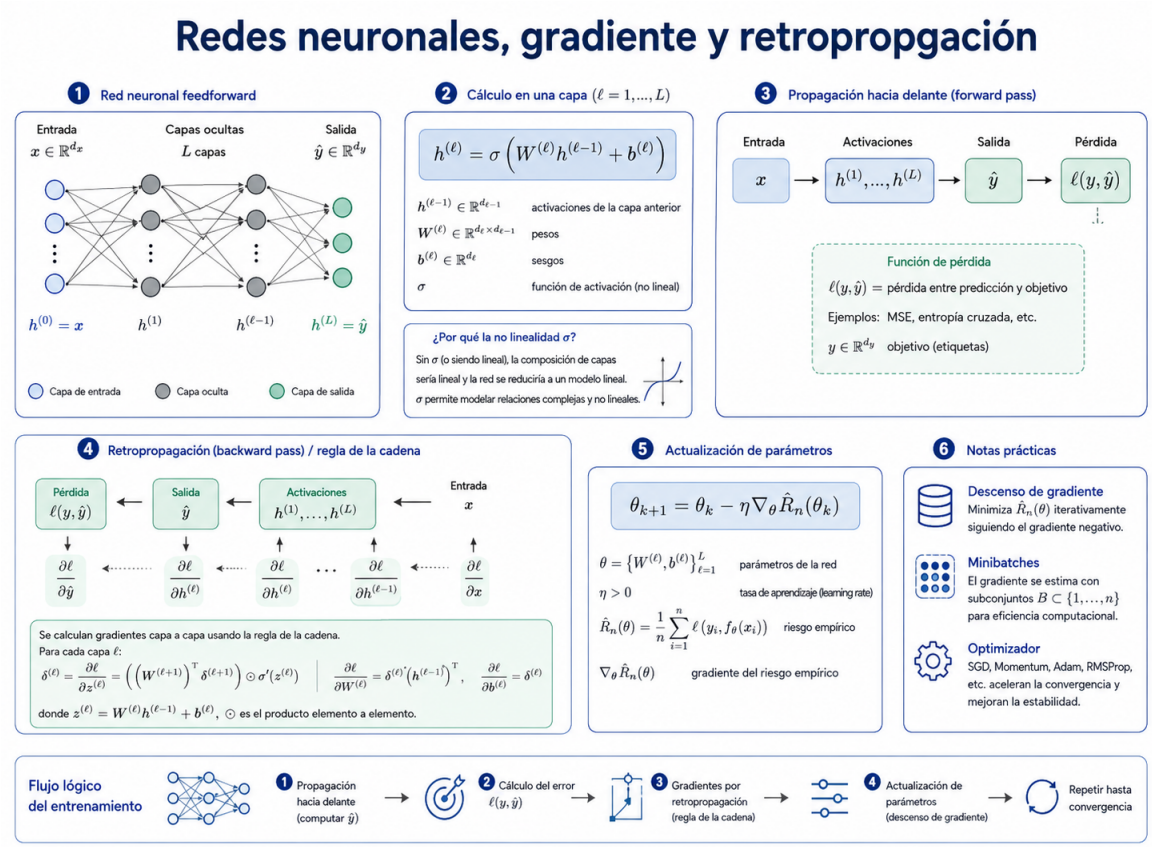


Figura 3.2: Esquema de una red neuronal feedforward y del entrenamiento mediante propagación hacia delante, cálculo de la pérdida, retropropagación del gradiente y actualización iterativa de parámetros.

(c) **Propagación hacia atrás (*backward*).** El error de la capa final se propaga hacia las capas anteriores. Definimos

$$\delta^{(\ell)} = \frac{\partial \ell}{\partial z^{(\ell)}}.$$

El caso base de la recursión corresponde a la capa de salida L: aplicando la regla de la cadena a $\ell(y, \hat{y})$ con $\hat{y} = \sigma^{(L)}(z^{(L)})$ se obtiene

$$\delta^{(L)} = \frac{\partial \ell}{\partial \hat{y}} \odot (\sigma^{(L)})'\big(z^{(L)}\big).$$

Para las capas ocultas $\ell < L$, la regla de la cadena da lugar a una relación del tipo

$$\delta^{(\ell)} = \Big((W^{(\ell+1)})^T \delta^{(\ell+1)}\Big) \odot (\sigma^{(\ell)})'\big(z^{(\ell)}\big),$$

donde $\odot$ denota el producto de Hadamard (producto componente a componente). Una vez calculado $\delta^{(\ell)}$, las derivadas respecto a los parámetros de esa capa son

$$\frac{\partial \ell}{\partial W^{(\ell)}} = \delta^{(\ell)} (h^{(\ell-1)})^T, \qquad \frac{\partial \ell}{\partial b^{(\ell)}} = \delta^{(\ell)}.$$

Por tanto, la retropropagación no es un método de optimización distinto del descenso de gradiente, sino el procedimiento que permite calcular eficientemente los gradientes que después usa el optimizador. En las implementaciones actuales, bibliotecas como *PyTorch* construyen el grafo computacional de la red y aplican automáticamente estas derivadas, pero el principio matemático sigue siendo la regla de la cadena aplicada capa a capa.

Esquema de entrenamiento en este trabajo

En los modelos utilizados en este TFG, el entrenamiento sigue un patrón común:

- A partir del conjunto de NO_2 preprocesado se construyen conjuntos de entrenamiento, validación y prueba. En las series temporales se respeta el orden temporal, utilizando segmentos iniciales para entrenar y segmentos posteriores para validar y probar.
- El conjunto de entrenamiento se recorre en *minibatches* de tamaño fijo (por ejemplo, entre 32 y 256 ejemplos). En cada minibatch se calcula la pérdida media y el gradiente correspondiente, y se actualizan los parámetros mediante un optimizador basado en gradiente, típicamente Adam.
- El proceso se repite durante varias épocas, monitorizando la pérdida sobre el conjunto de validación. Cuando esta pérdida deja de mejorar durante un número predefinido de épocas, se detiene el entrenamiento (*early stopping*) y se conservan los parámetros asociados a la mejor pérdida de validación.

En las redes LSTM, la construcción de los minibatches tiene en cuenta la estructura secuencial de los datos (ventanas temporales de longitud L). En la GAN, el entrenamiento alterna entre actualizaciones del discriminador y del generador, utilizando pérdidas distintas pero manteniendo el mismo esquema de optimización mediante gradientes sobre minibatches.

3.4 Capacidad del modelo, sobreajuste y regularización

De manera intuitiva, la *capacidad* de un modelo mide cuántos patrones distintos puede representar. Un modelo con capacidad muy baja (pocos parámetros, arquitectura muy simple) puede ser incapaz de

capturar la estructura de los datos (*infraajuste*). Un modelo con capacidad muy alta (muchos parámetros, arquitectura muy profunda o ancha) puede representar funciones muy complejas y, si la muestra disponible es limitada, corre el riesgo de ajustar también el ruido (*sobreajuste*) [2, cap. 5, p. 110].
En redes neuronales, la capacidad aumenta con el número de capas, el número de neuronas por capa, el tipo de activaciones y, en general, con el número total de parámetros. Para evaluar empíricamente si se está produciendo sobreajuste, se comparan los errores de entrenamiento y validación: si el error en entrenamiento es muy bajo pero el error en validación o prueba es significativamente mayor, es una señal de sobreajuste.
Para controlar este fenómeno se emplean técnicas de *regularización*, que introducen restricciones explícitas o implícitas sobre la familia de modelos o el procedimiento de entrenamiento. De forma general, estas técnicas modifican el principio de minimización del riesgo empírico introduciendo un término adicional $\Omega(\theta)$ que penaliza la complejidad del modelo:

$$\hat{\theta}_n \in \arg\min_{\theta\in\Theta} \hat{\mathcal{R}}_n(\theta) + \lambda\,\Omega(\theta), \qquad \lambda \geq 0,$$

donde λ controla el compromiso entre ajuste a los datos y complejidad del modelo. Algunas de las elecciones más habituales para Ω son:

- **Penalización de normas: Ridge (L2) y Lasso (L1).** La penalización Ridge corresponde a $\Omega(\theta) = \|\theta\|_2^2$,
$$\|\theta\|_2^2,$$
que favorece pesos pequeños y repartidos entre las variables. La penalización Lasso corresponde a $\Omega(\theta) = \|\theta\|_1$,
$$\|\theta\|_1,$$
que puede favorecer soluciones más dispersas. En ambos casos $\lambda > 0$ controla la intensidad de la penalización.

- **Detención temprana (*early stopping*).** Se detiene el entrenamiento cuando la pérdida de validación deja de mejorar, aunque la pérdida de entrenamiento continúe disminuyendo. Este procedimiento actúa como una regularización implícita: evita que el modelo se siga ajustando a detalles específicos de la muestra.

- **Dropout y ruido.** Se introducen perturbaciones durante el entrenamiento, por ejemplo anulando aleatoriamente neuronas (dropout) o añadiendo ruido a las entradas o activaciones, con el objetivo de favorecer representaciones robustas frente a pequeñas variaciones en los datos.

Además de estas técnicas, la capacidad se controla mediante decisiones de arquitectura: el número de capas y neuronas de las redes, la longitud de las ventanas temporales en modelos secuenciales, o el tamaño del espacio latente en la GAN, entre otros.
En los modelos utilizados en este proyecto se han tomado decisiones explícitas en esta dirección: se emplean arquitecturas LSTM de tamaño moderado, se introduce regularización L2 mediante *weight decay* en los optimizadores de PyTorch, se recurre al *early stopping* guiado por la pérdida de validación y los resultados finales se evalúan sobre un conjunto de prueba separado. El objetivo es que los modelos profundos utilizados (LSTM y GAN) sean lo suficientemente expresivos para el problema abordado, pero manteniendo un control sobre el sobreajuste y permitiendo comparaciones significativas dentro del *pipeline* de rutas de mínima exposición desarrollado en los capítulos posteriores.

Capítulo 4

Modelo espacial de calidad del aire y formulación de rutas de mínima exposición

En principio, los datos de NO_2 se presentan de forma discreta en las estaciones de calidad del aire. Para utilizarlos a lo largo de la ciudad, definiremos un campo continuo y un coste de exposición asociado a cada tramo de la red viaria. Es así como se formaliza matemáticamente el problema de encontrar rutas peatonales de mínima exposición entre dos puntos dados de València.
El capítulo se dividirá de la siguiente manera. En la Sección 4.1 se introduce la representación espacial de las estaciones y el sistema de coordenadas empleado. En la Sección 4.2 se presenta el método de interpolación por distancia inversa (IDW) utilizado para obtener un campo continuo de NO_2. La Sección 4.3 describe la construcción de la red de calles como grafo ponderado y la definición del coste de exposición asociado a cada arista.

4.1 Representación espacial de las estaciones

Denotemos por $S = \{1, \dots, N\}$ el conjunto de estaciones. Cada estación $s \in S$ tiene asociadas:

- unas coordenadas geográficas $(\text{lat}_s, \text{lon}_s)$,
- una serie temporal de mediciones de NO_2, $(\text{NO2}_s(t))_{t \in T}$, obtenida tras el preprocesamiento descrito en el Capítulo 2.

Para trabajar con distancias euclídeas en el plano, resulta conveniente proyectar las coordenadas geográficas a un sistema de coordenadas cartesianas (x, y), mediante una proyección adecuada para la escala de la ciudad. Esta proyección no modifica las mediciones de contaminación: únicamente expresa las posiciones en un sistema métrico local, de forma que las distancias entre estaciones, los radios de interpolación y las longitudes de las aristas puedan medirse en metros o kilómetros. Tras esta transformación, a cada estación s se asocia un punto

$$\mathbf{x}_s = (x_s, y_s) \in \mathbb{R}^2,$$

de modo que la distancia euclídea entre estaciones s y s' viene dada por

$$d(\mathbf{x}_s, \mathbf{x}_{s'}) = \left\| \mathbf{x}_s - \mathbf{x}_{s'} \right\| = \sqrt{(x_s - x_{s'})^2 + (y_s - y_{s'})^2}.$$

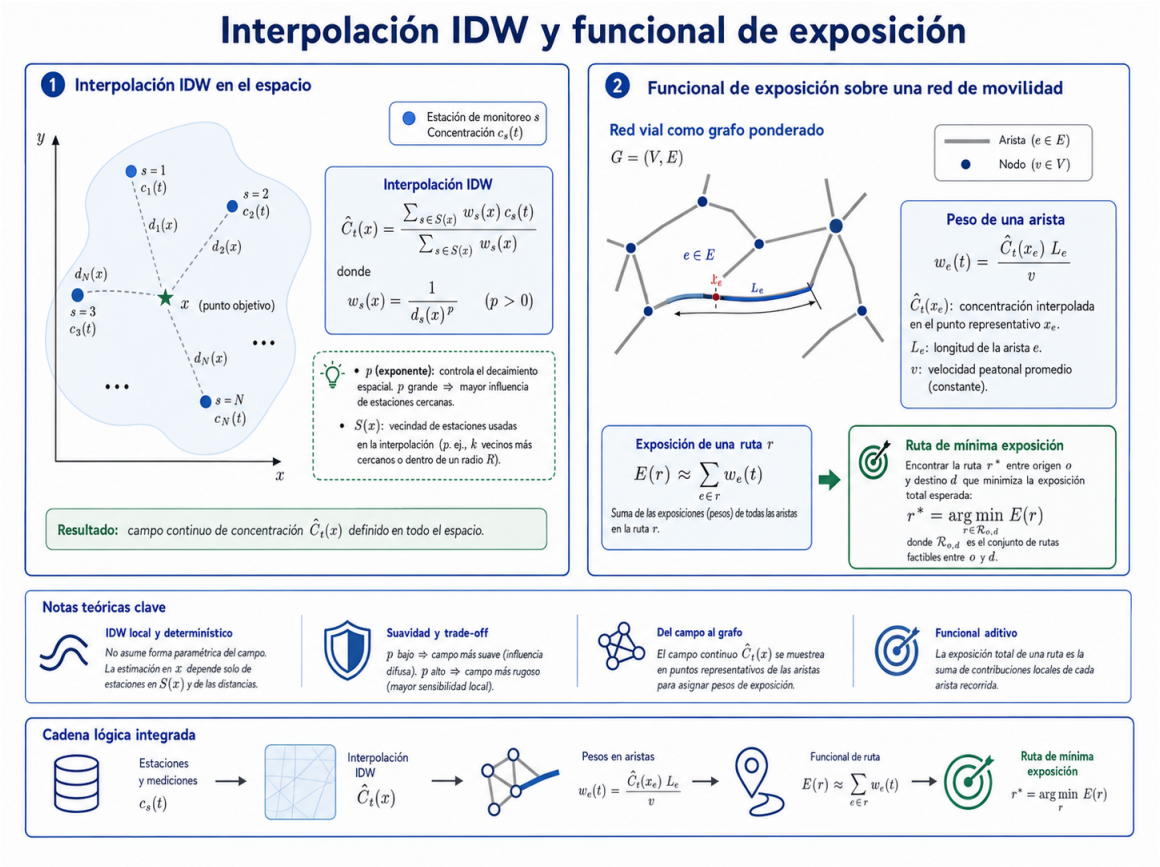


Figura 4.1: Relación entre la interpolación por ponderación inversa de la distancia y el funcional de exposición sobre una red de movilidad. A partir de mediciones puntuales en estaciones se obtiene un campo aproximado de concentración y, posteriormente, pesos ambientales sobre las aristas del grafo.

4.2 Interpolación por ponderación inversa de la distancia

En adelante, fijado un instante de tiempo t, denotaremos por $c_s(t) = \mathrm{NO2}_s(t)$ la concentración de NO_2 observada en la estación $s \in S$ en ese instante.
Las mediciones de NO_2 están disponibles únicamente en las estaciones de la red, es decir, en los puntos $\mathbf{x}_s$, $s \in S$. Sin embargo, para evaluar la exposición a lo largo de una ruta peatonal necesitamos una aproximación de la concentración en puntos arbitrarios del plano, en particular sobre los tramos de la red viaria.
Para ello utilizamos la interpolación por distancia inversa (*Inverse Distance Weighting*, IDW), un método clásico en geociencia y sistemas de información geográfica [6, 7]. La idea básica es que el valor en un punto $\mathbf{x}$ se obtiene como una media ponderada de las mediciones de las estaciones cercanas, donde las estaciones más próximas tienen mayor peso.

Definición del interpolador por ponderación inversa de la distancia

Sea t un instante de tiempo fijo y consideremos las concentraciones $c_s(t)$, $s \in S$. Dado un punto $\mathbf{x} \in \mathbb{R}^2$, se define la distancia a la estación s como

$$d_s(\mathbf{x}) = d(\mathbf{x}, \mathbf{x}_s) = \big\|\mathbf{x} - \mathbf{x}_s\big\|.$$

Fijemos un exponente $p > 0$ y, opcionalmente, un radio máximo $R > 0$ o un número máximo K de estaciones vecinas. El interpolador IDW se define como

$$\widehat{C}_t(\mathbf{x}) = \frac{\displaystyle\sum_{s \in S(\mathbf{x})} w_s(\mathbf{x})\, c_s(t)}{\displaystyle\sum_{s \in S(\mathbf{x})} w_s(\mathbf{x})},$$

donde $\widehat{C}_t(\mathbf{x})$ representa la concentración interpolada en el punto $\mathbf{x}$ y en el instante t. En esta expresión:

- $S(\mathbf{x}) \subseteq S$ es el conjunto de estaciones que intervienen en la interpolación en el punto $\mathbf{x}$ (por ejemplo, las K estaciones más cercanas o las situadas a distancia menor que R),
- los pesos $w_s(\mathbf{x})$ dependen de la distancia a cada estación. Una elección habitual es

  $$w_s(\mathbf{x}) = \frac{1}{d_s(\mathbf{x})^p},$$

  de modo que las estaciones más cercanas tienen mayor influencia, y la influencia decrece como una potencia de la distancia.

Observamos que la normalización por la suma $\sum_{s \in S(\mathbf{x})} w_s(\mathbf{x})$ garantiza que la interpolación es una media ponderada de los valores $c_s(t)$, esto es,

$$\widehat{C}_t(\mathbf{x}) = \sum_{s \in S(\mathbf{x})} \lambda_s(\mathbf{x})\, c_s(t), \qquad \lambda_s(\mathbf{x}) \geq 0, \qquad \sum_{s \in S(\mathbf{x})} \lambda_s(\mathbf{x}) = 1.$$

Además, en el caso particular en que $\mathbf{x}$ coincide exactamente con la posición de una estación, $\mathbf{x} = \mathbf{x}_s$, el peso $w_s(\mathbf{x}) = d_s(\mathbf{x})^{-p}$ diverge cuando $d_s(\mathbf{x}) \to 0$. Sin embargo, dicho peso aparece tanto en el numerador como en el denominador de $\widehat{C}_t(\mathbf{x})$, multiplicando en ambos casos a $c_s(t)$ y a 1 respectivamente; los términos correspondientes al resto de estaciones $s' \neq s$ permanecen acotados, de

modo que, al dividir numerador y denominador por $w_s(\mathbf{x})$ y tomar el límite, ambos cocientes tienden a 0 salvo el término en s, que tiende a 1. Por tanto

$$\lim_{\mathbf{x}\to\mathbf{x}_s} \widehat{C}_t(\mathbf{x}) = c_s(t),$$

es decir, el interpolador es consistente con las observaciones: en la práctica, este caso se trata como un límite y se define $\widehat{C}_t(\mathbf{x}_s) := c_s(t)$.
Respecto a los parámetros de la interpolación IDW:

- El exponente p controla cómo decrece el peso con la distancia. Valores mayores de p hacen que la interpolación dependa principalmente de las estaciones más cercanas, produciendo campos más localizados; valores pequeños de p generan campos más suaves y globales.
- El radio R o el número de vecinos K determinan cuántas estaciones contribuyen en cada punto. Considerar únicamente las estaciones más cercanas evita que estaciones muy lejanas influyan en zonas donde su información es menos relevante.

En este trabajo se seleccionan mediante validación cruzada *leave-one-station-out*: para un conjunto de candidatos $p \in \{1, 1.5, 2, 2.6, 3\}$ y $K \in \{2, 3, 4\}$, se omite iterativamente cada una de las $N = 11$ estaciones, se interpola su concentración a partir del resto y se calcula el error cuadrático medio entre el valor interpolado y el observado. La combinación ($R = 3\,\text{km}$, $K = 3$, $p = 2.6$) minimiza el RMSE de validación cruzada promediado sobre estaciones e instantes de tiempo, y es la que se emplea en los capítulos de resultados. Un valor de p superior a 2 refleja que la variabilidad espacial de NO_2 en la escala de la ciudad de València es relativamente local, con gradientes importantes en torno a las vías de mayor tráfico.

4.3 Red viaria y coste de exposición

Una vez definido el campo interpolado $\mathbf{x} \mapsto \widehat{C}_t(\mathbf{x})$, el siguiente paso consiste en formalizar el problema de rutas de mínima exposición sobre la red de calles. Como no se tiene en cuenta únicamente la longitud del tramo, sino también su concentración de NO_2, se modela la red viaria como un grafo ponderado, donde cada arista representa un tramo de calle y su peso incorporará ambos parámetros.

Grafo de la red viaria

La red de calles se representa mediante un grafo

$$G = (V, E),$$

donde:

- V es el conjunto de nodos, que representan intersecciones, extremos de tramos de calle u otros puntos relevantes de la red;
- E es el conjunto de aristas, donde cada arista $e = (u, v) \in E$ representa un tramo de calle que conecta los nodos $u, v \in V$.

A cada arista $e \in E$ se le asocia:

- una longitud $L_e > 0$, que puede calcularse a partir de las coordenadas geográficas de sus extremos;

- un punto representativo $\mathbf{x}_e$ sobre el tramo (por ejemplo, su punto medio) al que se asociará la concentración de NO_2.

Por último, para modelar el tiempo de recorrido se fija una velocidad peatonal media $v > 0$. El tiempo necesario para recorrer la arista e es entonces

$$T_e = \frac{L_e}{v}.$$

En este trabajo se adopta $v = 4.8$ km/h, valor que corresponde a la velocidad media de marcha a pie habitual en adultos en entorno urbano plano, ampliamente utilizado en la literatura de movilidad activa y planificación de rutas peatonales [10, 11]. La planitud del casco urbano de València hace que esta aproximación sea especialmente adecuada en comparación con ciudades con pendientes pronunciadas.

Concentración por tramo y funcional de exposición

Fijado un instante de tiempo t y el campo interpolado $\widehat{C}_t$, se aproxima la concentración de NO_2 a lo largo de la arista e mediante el valor del campo en el punto representativo:

$$c_e(t) \approx \widehat{C}_t(\mathbf{x}_e).$$

Esta aproximación corresponde a una *cuadratura de tipo punto medio compuesta*: se divide el intervalo temporal $[0, T_\gamma]$ en subintervalos $T_{e_j} = L_{e_j}/v$ y se evalúa el integrando en el punto representativo $\mathbf{x}_{e_j}$ de cada tramo. Si $\alpha \mapsto \widehat{C}_t(\mathbf{x}(\alpha))$ es de clase C^1, el error local en cada tramo es $\mathcal{O}(T_{e_j}^2)$ y el error global de la suma es $\mathcal{O}(L_e)$, donde L_e denota la longitud máxima de los tramos; en la red peatonal de València obtenida de OpenStreetMap con modo `walk`, la longitud media de los tramos es del orden de 50–80 metros, por lo que dicho error es pequeño frente a la incertidumbre propia de la interpolación IDW.
Desde el punto de vista físico, fijado el instante de referencia t, la *exposición acumulada* a NO_2 de un peatón que recorre una trayectoria γ puede modelarse mediante el campo interpolado como la integral

$$\mathcal{E}_t(\gamma) = \int_0^{T_\gamma} \widehat{C}_t\big(\mathbf{x}(\alpha)\big)\, \mathrm{d}\alpha,$$

donde $\mathbf{x}(\alpha)$ describe la posición del peatón a lo largo del recorrido, $\widehat{C}_t(\mathbf{x}(\alpha))$ es la concentración interpolada en esa posición y T_γ es la duración total de la trayectoria.
En el marco discreto del grafo, una ruta desde un nodo origen $o \in V$ hasta un nodo destino $d \in V$ se representa como una sucesión de aristas

$$r = (e_1, e_2, \ldots, e_m),$$

y la integral anterior se aproxima mediante la suma

$$\mathcal{E}_t(r) \approx \sum_{j=1}^{m} c_{e_j}(t)\, T_{e_j} = \sum_{j=1}^{m} \widehat{C}_t(\mathbf{x}_{e_j})\, \frac{L_{e_j}}{v}.$$

Es decir, la exposición acumulada a lo largo de la ruta se aproxima como la suma, para cada tramo, del producto entre la concentración estimada en el tramo y el tiempo necesario para recorrerlo.
Esto sugiere definir, para cada arista $e \in E$, un peso

$$w_e(t) = \widehat{C}_t(\mathbf{x}_e)\, \frac{L_e}{v},$$

de modo que la exposición aproximada de una ruta r viene dada por

$$\mathcal{E}_t(r) \approx \sum_{e \in r} w_e(t).$$

Con la definición anterior, el problema de encontrar una ruta de mínima exposición entre dos nodos $o, d \in V$ se traduce en un problema de caminos mínimos en un grafo ponderado: se trata de encontrar una sucesión de aristas $r = (e_1, \ldots, e_m)$ que conecte o con d y minimice la suma de pesos

$$\sum_{e \in r} w_e(t).$$

Este problema puede resolverse mediante algoritmos clásicos de caminos mínimos en grafos, como el algoritmo de Dijkstra o variantes informadas del tipo A*, adaptados al caso en que todos los pesos $w_e(t)$ son positivos. No se profundiza aquí en estos algoritmos, pero basta saber que proporcionan de forma eficiente rutas que minimizan el coste definido sobre el grafo.
El resultado es, para cada instante de tiempo t considerado, una ruta peatonal que equilibra tiempo de recorrido y niveles de NO_2, en el sentido del funcional de exposición $\mathcal{E}(r)$.

Capítulo 5

Modelo secuencial para la predicción temporal de concentraciones

En este capítulo se describe el modelo de *Long Short-Term Memory* (LSTM) empleado para predecir la evolución temporal de las concentraciones de NO_2 en las estaciones de la ciudad de València y, a partir de dichas predicciones, construir campos espaciales de contaminación futuros. Se comienza formulando el problema de predicción como una tarea supervisada sobre series temporales, se introduce la célula LSTM y, finalmente, se detalla la arquitectura y el esquema de entrenamiento utilizados en este Trabajo Fin de Grado.

5.1 Formulación del problema de predicción temporal

Sea s una estación de la red de calidad del aire y consideremos la serie temporal de NO_2 en dicha estación. Denotamos por

$$u_t^{(s)} = \mathrm{NO2}_s(t), \qquad t \in T,$$

la observación escalar de NO_2 en la estación s en el instante t, muestreada a resolución temporal fija. Para cada instante $t \in T$ se define una *ventana temporal* de longitud L:

$$X_t^{(s)} = \left(u_{t-L+1}^{(s)}, u_{t-L+2}^{(s)}, \ldots, u_t^{(s)}\right) \in \mathbb{R}^L.$$

Es decir, $X_t^{(s)}$ recoge las L últimas observaciones disponibles de NO_2 en la estación s hasta el tiempo t. Esta notación separa el valor individual $u_t^{(s)}$ de la ventana completa $X_t^{(s)}$, que es el verdadero objeto de entrada del modelo.
Fijado un horizonte de predicción $\tau > 0$ (por ejemplo, $\tau = 60$ minutos), la variable objetivo asociada a la ventana $X_t^{(s)}$ es

$$y_t^{(s)} = u_{t+\tau}^{(s)},$$

la concentración futura de NO_2 en la misma estación y en el tiempo $t + \tau$.
En esta formulación:

- el *espacio de entrada* es $\mathcal{X} = \mathbb{R}^L$,
- el *espacio de salida* es $\mathcal{Y} = \mathbb{R}$,
- cada par $(X_t^{(s)}, y_t^{(s)})$ constituye un ejemplo supervisado.

Para cada estación (o, en una variante, para un conjunto de estaciones agregadas) se construye una muestra finita de ejemplos

$$\mathcal{D}_n = \{(X_{t_i}^{(s)}, y_{t_i}^{(s)})\}_{i=1}^n,$$

a partir de los datos históricos disponibles. La tarea de predicción se formula como el problema de encontrar una función $f_\theta : \mathbb{R}^L \to \mathbb{R}$ tal que $f_\theta(X_t^{(s)})$ sea una buena aproximación de $y_t^{(s)}$ en el sentido del riesgo empírico introducido en el Capítulo 3.
Como función de pérdida se utiliza el error cuadrático medio (MSE),

$$\ell(y, \hat{y}) = (y - \hat{y})^2,$$

de modo que el riesgo empírico asociado a un modelo f_θ y a la muestra $\mathcal{D}_n$ viene dado por

$$\hat{\mathcal{R}}_n(\theta) = \frac{1}{n} \sum_{i=1}^{n} \left(y_{t_i}^{(s)} - f_\theta(X_{t_i}^{(s)}) \right)^2.$$

El objetivo es encontrar parámetros θ que minimicen (aproximadamente) $\hat{\mathcal{R}}_n(\theta)$ y proporcionen buenas predicciones sobre ventanas temporales no utilizadas en el entrenamiento, es decir, que tengan buen rendimiento de generalización.
En la implementación final de este trabajo se emplea una resolución temporal de 10 minutos y una ventana de longitud $L = 144$ (equivalente a 24 horas), con un horizonte de predicción $\tau = 60$ minutos. Es decir, el modelo aprende a predecir la concentración de NO_2 una hora por delante a partir de la evolución del contaminante durante el día anterior.

5.2 La arquitectura de memoria a largo y corto plazo

De forma informal, una red LSTM puede imaginarse como una cadena de "células" conectadas a lo largo del tiempo. En cada instante t, una *célula LSTM* recibe como entrada:

- el dato actual de la secuencia (en nuestro caso, el valor de NO_2 en el instante t),
- y un *estado interno* que viene del pasado, formado por dos vectores: el estado oculto h_{t-1} y el estado de memoria c_{t-1}.

A partir de esa información, la célula LSTM calcula un nuevo estado de memoria c_t, un nuevo estado oculto h_t y, en nuestro modelo, una contribución a la predicción. Es decir, una célula LSTM es la unidad básica que, dada la entrada actual y lo que "recuerda" del pasado, decide qué olvidar, qué información nueva guardar y qué sacar hacia la salida. Las ecuaciones que escribimos a continuación describen precisamente cómo realiza esa operación cada célula.
Las redes neuronales recurrentes clásicas (*Recurrent Neural Networks*, RNN) sufren problemas de gradientes desvanecidos o explosivos cuando se entrenan sobre secuencias largas, lo que dificulta el aprendizaje de dependencias a largo plazo en series temporales [2, cap. 10, p. 397]. Las redes LSTM (*Long Short-Term Memory*) se introdujeron precisamente para mitigar estos problemas mediante una arquitectura recurrente con una *memoria interna* y un sistema de compuertas que controla el flujo de información [4, 5].

Notación

Para simplificar, consideremos una única capa LSTM. Dentro de una ventana temporal $X_t^{(s)}$, indexamos los pasos internos por k. En cada paso local k la entrada de la célula es un vector $x_k \in \mathbb{R}^{d_{\text{in}}}$; en el caso univariante de este trabajo, x_k contiene el valor escalado de NO_2 correspondiente a ese instante de la ventana. La célula mantiene dos vectores de estado:

- el estado oculto $h_k \in \mathbb{R}^{d_{\text{hid}}}$,
- el estado de la celda $c_k \in \mathbb{R}^{d_{\text{hid}}}$,

donde d_{hid} es el número de unidades LSTM. Esta notación reserva $X_t^{(s)}$ para la ventana completa y usa x_k únicamente para la entrada que la célula recibe en un paso interno de dicha ventana.
La célula LSTM define, en cada paso, las siguientes variables intermedias:

$$i_k, f_k, o_k, \tilde{c}_k \in \mathbb{R}^{d_{\text{hid}}},$$

que corresponden, respectivamente, a la *compuerta de entrada*, la *compuerta de olvido*, la *compuerta de salida* y el *estado candidato*.

Ecuaciones de actualización

Siguiendo la formulación estándar [2, 1], la célula LSTM se define mediante las ecuaciones:

$$\begin{aligned} i_k &= \sigma\big(W_i x_k + U_i h_{k-1} + b_i\big), \\ f_k &= \sigma\big(W_f x_k + U_f h_{k-1} + b_f\big), \\ o_k &= \sigma\big(W_o x_k + U_o h_{k-1} + b_o\big), \\ \tilde{c}_k &= \tanh\big(W_c x_k + U_c h_{k-1} + b_c\big), \end{aligned}$$

donde σ es la función sigmoide logística, aplicada componente a componente; $W_\bullet$ y $U_\bullet$ son matrices de pesos; y $b_\bullet$ son vectores de sesgos.
A partir de estas variables se actualiza el estado de la celda

$$c_k = f_k \odot c_{k-1} + i_k \odot \tilde{c}_k,$$

y el estado oculto

$$h_k = o_k \odot \tanh(c_k),$$

donde $\odot$ denota el producto de Hadamard, definido en el Capítulo 3.

Interpretación

La interpretación de estas ecuaciones es la siguiente:

- La compuerta de olvido f_k controla qué parte del estado anterior c_{k-1} se conserva. Si un componente de f_k es cercano a 1, la información correspondiente en c_{k-1} se mantiene; si es cercano a 0, se olvida.
- La compuerta de entrada i_k decide cuánto de la nueva información contenida en el estado candidato $\tilde{c}_k$ se incorpora a la memoria.
- El estado de la celda c_k combina, por tanto, memoria antigua y actualización nueva, lo que permite mantener información relevante durante muchos pasos de tiempo.
- La compuerta de salida o_k controla cuánto de la memoria interna se expone al exterior a través del estado oculto h_k.

El motivo matemático de esta mitigación se observa directamente en la ecuación de actualización del estado de la celda, $c_k = f_k \odot c_{k-1} + i_k \odot \tilde{c}_k$: derivando respecto a c_{k-1} se obtiene $\partial c_k / \partial c_{k-1} = \operatorname{diag}(f_k)$, un camino *aditivo* cuyo factor de propagación es la compuerta de olvido. Si $f_k \approx 1$, el gradiente atraviesa muchos pasos sin atenuarse por un producto de jacobianos no acotado, a diferencia de las RNN simples, donde $\partial h_k / \partial h_{k-1}$ involucra productos repetidos de matrices de pesos y derivadas de activaciones que pueden anularse o explotar exponencialmente con el número de pasos. Gracias a

esta estructura con auto-bucles y compuertas, las LSTM son capaces de modelar dependencias de largo alcance en series temporales sin sufrir, en la misma medida, los problemas de gradientes desvanecidos de las RNN simples [4, 5, 2].
En el contexto de este trabajo, la secuencia de entrada es la ventana $X_t^{(s)} = (u_{t-L+1}^{(s)}, \ldots, u_t^{(s)})$, formada por las últimas L observaciones univariantes de NO_2 tras el escalado correspondiente. La red procesa esas observaciones paso a paso, actualizando (h_k, c_k), y a partir del estado final de la ventana genera la predicción futura $f_\theta(X_t^{(s)})$ mediante una capa lineal.

5.3 Arquitectura y esquema de entrenamiento utilizados

Arquitectura del modelo

El modelo LSTM empleado en este trabajo se puede describir de forma esquemática como sigue:

- **Entrada.** Ventanas $X_t^{(s)} \in \mathbb{R}^L$ que contienen los L últimos valores escalados de NO_2 en la estación considerada. En la implementación utilizada, cada secuencia de entrada tiene longitud $L = 144$.
- **Capa LSTM.** Una o varias capas LSTM con d_{hid} unidades ocultas (por ejemplo, entre 32 y 128), que procesan la ventana paso a paso y producen una secuencia de estados ocultos.
- **Capa de salida.** Se toma el último estado oculto de la ventana y se aplica una capa lineal

$$\hat{y}_t = W_{\text{out}} h_{\text{final}} + b_{\text{out}},$$

que devuelve la predicción escalada de NO_2 en el horizonte $t + \tau$. Mediante la transformación inversa del escalado se recupera el valor en las unidades originales.

En notación compacta, la red define una función

$$f_\theta : \mathbb{R}^L \to \mathbb{R},$$

donde θ recoge todos los parámetros de la capa LSTM y de la capa de salida. El tamaño concreto de d_{hid}, el número de capas LSTM y la presencia o no de técnicas adicionales (dropout entre capas, por ejemplo) se eligen en función del compromiso entre capacidad y riesgo de sobreajuste, siguiendo las consideraciones del Capítulo 3.

Preparación de los datos y partición temporal

A partir de la serie de NO_2 escalada en cada estación se construyen las ventanas (x_t, y_t) mediante un esquema deslizante con paso fijo (por ejemplo, 10 minutos). La muestra $\mathcal{D}_n$ resultante se divide en tres subconjuntos:

- un conjunto de *entrenamiento*, formado por las ventanas más antiguas;
- un conjunto de *validación*, formado por ventanas posteriores, que se utiliza para ajustar hiperparámetros y aplicar *early stopping*;
- un conjunto de *prueba*, formado por las ventanas más recientes, que se reserva para la evaluación final del modelo.

Esta partición respeta la estructura temporal de la serie (no se barajan las ventanas), de modo que la evaluación en validación y prueba simula predicciones futuras a partir de datos pasados.

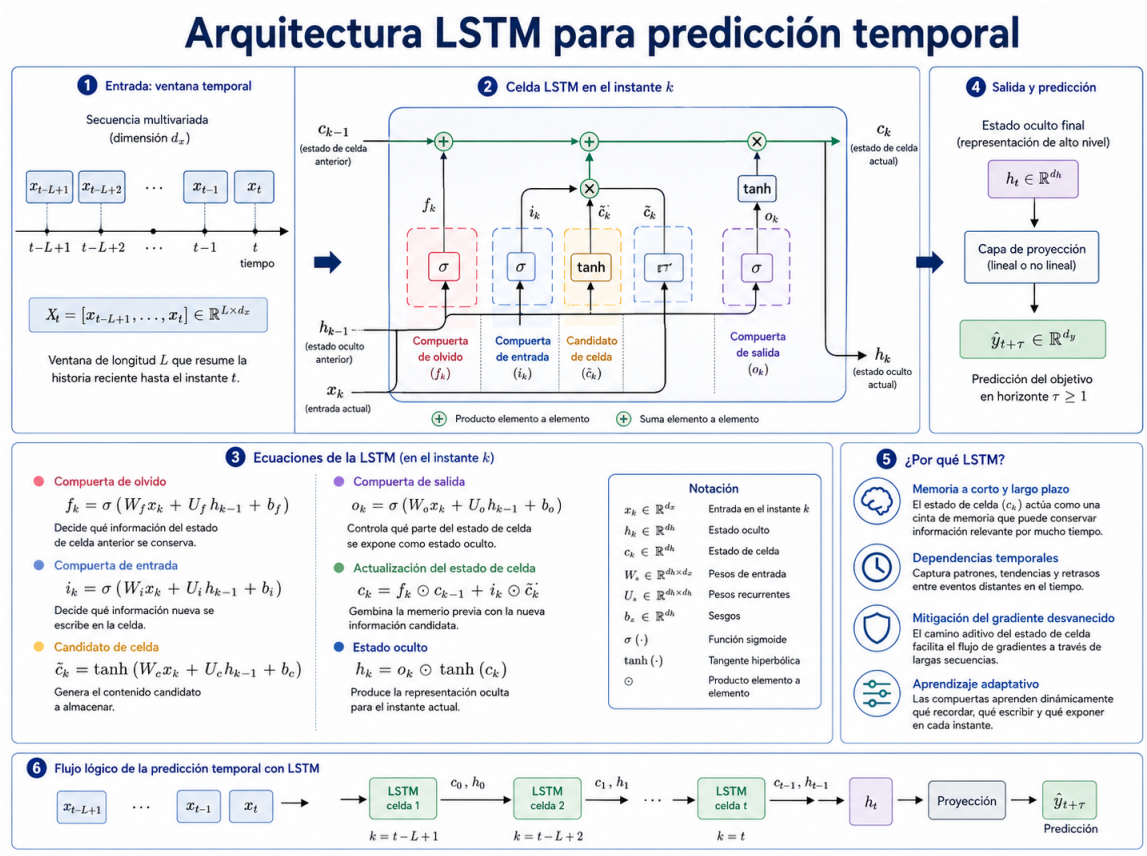


Figura 5.1: Arquitectura de una célula de memoria a largo y corto plazo aplicada a predicción temporal. La ventana de entrada se procesa secuencialmente mediante compuertas de olvido, entrada y salida, hasta obtener una representación final que alimenta la predicción futura.

Entrenamiento mediante descenso de gradiente

El entrenamiento se realiza minimizando el error cuadrático medio (MSE) sobre el conjunto de entrenamiento mediante un optimizador basado en gradiente, típicamente Adam, tal y como se describió en el Capítulo 3. En cada época:

(a) Se recorren las ventanas de entrenamiento en *minibatches* de tamaño fijo.

(b) Para cada minibatch se calcula la pérdida media (MSE) y se obtiene el gradiente respecto a los parámetros θ mediante retropropagación a través del tiempo.

(c) Se actualizan los parámetros con el optimizador elegido.

(d) Al final de la época se evalúa el MSE sobre el conjunto de validación.

Se aplica además *early stopping*: si la pérdida de validación deja de mejorar durante un número prefijado de épocas consecutivas, se detiene el entrenamiento y se conservan los parámetros correspondientes a la mejor pérdida de validación observada.

Uso de las predicciones en el *pipeline* de rutas

Una vez entrenado, el modelo LSTM proporciona, para cada estación s y cada ventana (x_t), una predicción $\hat{y}_t = f_\theta(x_t)$ de la concentración de NO_2 en el horizonte $t+\tau$. Para un instante de referencia t_0, se recopilan las predicciones de todas las estaciones

$$\left\{\hat{c}_s(t_0+\tau)\right\}_{s\in S},$$

donde $\hat{c}_s(t_0+\tau)$ denota la predicción en la estación s.
Estas predicciones se utilizan, en lugar de los valores observados, como entrada del interpolador por ponderación inversa de la distancia, definido en el Capítulo 4, obteniendo así un campo espacial previsto $\widehat{C}_{t_0+\tau}(\mathbf{x})$ y unos pesos $w_e(t_0+\tau)$ sobre las aristas del grafo viario. A partir de estos pesos se resuelve el problema de caminos mínimos para calcular rutas de mínima exposición en el futuro, permitiendo comparar:

- rutas basadas en campos construidos a partir de mediciones observadas (instantáneas),
- rutas basadas en campos construidos a partir de predicciones LSTM,
- y, posteriormente, rutas bajo escenarios generados por la red generativa adversaria.

Los resultados cuantitativos de predicción, medidos mediante el error medio absoluto (MAE), la raíz del error cuadrático medio (RMSE) y otras métricas afines, así como las comparaciones entre rutas, se presentan en el capítulo de resultados, donde se analizan por estación y por escenario temporal.

Capítulo 6

Modelo generativo para la construcción de escenarios de estrés

En este capítulo se describe de forma concisa el uso de *redes generativas adversarias* (GAN, *Generative Adversarial Networks*). El objetivo no es construir un modelo generativo exhaustivo, sino disponer de una herramienta que permita generar *escenarios de estrés* de NO_2 coherentes con los datos observados, sobre los que evaluar la robustez de las rutas de mínima exposición obtenidas en los capítulos anteriores.
La sección comienza recordando brevemente la idea básica de una red generativa adversaria y se centra a continuación en la configuración concreta utilizada, así como en la forma en que los escenarios generados se integran en el *pipeline* de rutas.

6.1 Motivación: escenarios de estrés del dióxido de nitrógeno

Los capítulos anteriores se han centrado en:

- construir campos espaciales de NO_2 a partir de mediciones observadas mediante interpolación por ponderación inversa de la distancia,
- predecir la evolución temporal de NO_2 con modelos de memoria a largo plazo (LSTM),
- y, a partir de estos campos, calcular rutas de mínima exposición sobre la red viaria.

Sin embargo, los datos disponibles cubren un número finito de situaciones meteorológicas y de tráfico. Es interesante disponer de una herramienta que permita simular *mapas plausibles* de NO_2 en escenarios que no aparecen exactamente en los datos, por ejemplo:

- concentraciones especialmente altas en ciertas zonas (episodios de contaminación);
- variaciones espaciales más acusadas que las observadas en un día típico;
- combinaciones poco frecuentes de patrones temporales y espaciales.

El uso de una red generativa adversaria persigue precisamente este objetivo: aprender, a partir de los datos observados, una distribución de probabilidad sobre campos espaciales de NO_2 y poder muestrear de ella para generar mapas sintéticos de contaminación que sean realistas pero no idénticos a los observados.

6.2 Esquema básico de una red generativa adversaria condicional

Una red generativa adversaria estándar [8, 2] consta de dos redes neuronales:

- un *generador* G_θ, que toma como entrada un vector de ruido z y produce una muestra sintética $G_\theta(z)$;
- un *discriminador* D_ϕ, que recibe como entrada una muestra x y devuelve una puntuación $D_\phi(x) \in (0, 1)$ interpretable como la probabilidad de que x sea real.

Ambas redes se entrenan conjuntamente mediante un juego de suma cero. En su forma más simple, el objetivo teórico se escribe como

$$\min_\theta \max_\phi \Big(\mathbb{E}_{x \sim p_{\text{datos}}}[\log D_\phi(x)] + \mathbb{E}_{z \sim p_z}[\log(1 - D_\phi(G_\theta(z)))] \Big),$$

donde p_{datos} es la distribución de los datos reales y p_z es una distribución sencilla (por ejemplo, una normal estándar) sobre el espacio latente. En este trabajo interesa generar instantáneas de NO_2 condicionadas a cierta información adicional, como la hora del día o el tipo de día (laborable/festivo). Para ello se utiliza una red generativa adversaria condicional: además del ruido z, tanto el generador como el discriminador reciben un vector de condicionamiento c.
Los detalles de optimización (elección de la variante de pérdida, trucos de entrenamiento, etc.) se ajustan siguiendo las recomendaciones prácticas habituales [2, 1], pero no son el foco principal de este trabajo.

6.3 Configuración utilizada en este trabajo

En la implementación concreta de este TFG se adopta una configuración deliberadamente sencilla, con el objetivo de mantener el énfasis en la aplicación a rutas de mínima exposición más que en el diseño de arquitecturas generativas complejas.

Representación de las instantáneas reales

La red generativa adversaria se entrena con datos reales observados en distintos instantes. Para cada instante t se considera el vector de concentraciones de NO_2 medido en las estaciones disponibles,

$$x(t) = \big(c_{s_1}(t), \ldots, c_{s_d}(t)\big) \in \mathbb{R}^d,$$

donde $s_1, \ldots, s_d$ son las estaciones utilizadas y $c_{s_j}(t)$ representa la concentración registrada en la estación s_j en el instante t, tras el preprocesamiento y escalado apropiados.
Por tanto, las muestras reales empleadas para entrenar la GAN no son campos continuos observados directamente sobre toda la ciudad, sino instantáneas reales de la red de estaciones en distintos tiempos. La interpolación espacial se aplica posteriormente, cuando un escenario generado debe trasladarse al grafo urbano para calcular concentraciones aproximadas sobre los tramos de la ruta.

Generador y discriminador

El generador G_θ toma como entrada:

- un vector de ruido z de dimensión moderada (por ejemplo, 16–32 componentes),
- un vector de condicionamiento c que codifica información como la hora del día o el tipo de día.

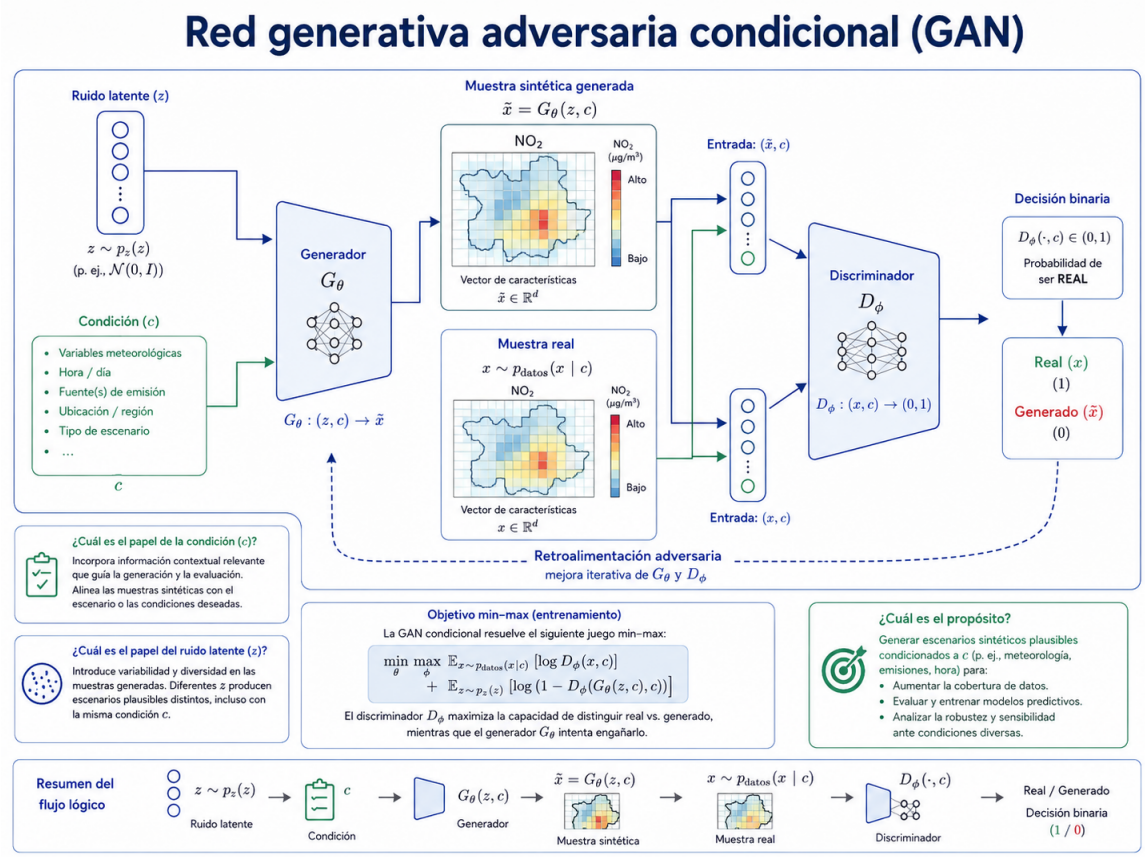


Figura 6.1: Esquema de una red generativa adversaria condicional. El generador produce una instantánea sintética condicionada a información contextual, mientras que el discriminador compara muestras reales y generadas para guiar el entrenamiento adversario.

A partir de (z, c), el generador produce un vector $G_\theta(z, c) \in \mathbb{R}^d$ que se interpreta como una instantánea sintética de NO_2 sobre la red de estaciones.
El discriminador D_ϕ recibe como entrada:

- una instantánea $x \in \mathbb{R}^d$, ya sea real o generada por G_θ,
- el mismo vector de condicionamiento c,

y devuelve una puntuación $D_\phi(x, c) \in (0, 1)$ que se entrena para aproximar la probabilidad de que (x, c) provenga de los datos reales y no del generador.
Ambas redes se implementan como composiciones de capas lineales y funciones de activación (por ejemplo, ReLU), siguiendo el marco general de redes neuronales del Capítulo 3. El tamaño y la profundidad de las redes se mantienen moderados para evitar sobreajuste y reducir el coste computacional.

Esquema de entrenamiento

El entrenamiento de la red generativa adversaria condicional sigue el esquema estándar:

(a) Se elige un *minibatch* de instantáneas reales $\{x^{(i)}\}$ y sus condicionamientos $\{c^{(i)}\}$.

(b) Se genera un conjunto de instantáneas sintéticas $\{G_\theta(z^{(i)}, c^{(i)})\}$ a partir de vectores de ruido $\{z^{(i)}\}$ muestreados de p_z.

(c) Se actualiza el discriminador D_ϕ para mejorar su capacidad de distinguir instantáneas reales de generadas.

(d) Se actualiza el generador G_θ para producir mapas que el discriminador clasifique como reales.

Este proceso se repite durante varias épocas, monitorizando tanto la estabilidad del entrenamiento como la plausibilidad visual y estadística de los mapas generados (por ejemplo, distribuciones de valores similares a las observadas).

6.4 Integración de la red generativa adversaria en el *pipeline* de rutas

El papel de la red generativa adversaria en este Trabajo Fin de Grado es proporcionar *escenarios de estrés* sobre los que evaluar el comportamiento de las rutas de mínima exposición. El procedimiento es el siguiente:

(a) Se fija un vector de condicionamiento c que representa la situación de interés (por ejemplo, una hora del día con tráfico intenso).

(b) Se generan múltiples instantáneas sintéticas $x^{(1)}, \ldots, x^{(M)}$ muestreando distintos vectores de ruido $z^{(1)}, \ldots, z^{(M)}$ y aplicando el generador: $x^{(j)} = G_\theta(z^{(j)}, c)$.

(c) Cada instantánea generada $x^{(j)}$ se traslada al grafo urbano mediante el esquema espacial del Capítulo 4. De este modo se obtiene una concentración aproximada en cada tramo e del grafo viario, lo que permite definir pesos $w_e^{(j)}$ análogos a los introducidos en el Capítulo 4.

(d) Para cada escenario generado se resuelve el problema de caminos mínimos y se obtiene una ruta de mínima exposición entre los puntos de interés.

Este enfoque permite responder a preguntas del tipo:

- ¿Cómo varían las rutas de mínima exposición cuando se consideran escenarios de contaminación espacialmente más heterogéneos que los observados en un día típico?
- ¿Se mantienen las mismas zonas de la ciudad como preferibles en términos de baja exposición bajo diferentes muestras de la distribución generada por la GAN?

En resumen, la red generativa adversaria no se utiliza como modelo principal de predicción, sino como una herramienta complementaria para generar escenarios plausibles de NO_2 y analizar la robustez de las rutas de mínima exposición frente a variaciones en el campo de contaminación. Los detalles cuantitativos y ejemplos gráficos de los escenarios generados se presentan en el capítulo de resultados.

Capítulo 7

Resultados empíricos en rutas de mínima exposición

En este capítulo se presentan los resultados numéricos de la planificación de rutas peatonales en la ciudad de València bajo distintos escenarios de contaminación por dióxido de nitrógeno (NO_2). El objetivo es cuantificar hasta qué punto un modelo secuencial LSTM, integrado en un esquema de planificación dinámica, permite reducir la exposición acumulada frente a estrategias estáticas basadas en un mapa fijo de contaminación, y cómo se comporta esta planificación cuando se someten los campos de NO_2 a *escenarios de estrés* generados mediante GAN.
Recordamos que, para cualquier ruta discreta γ parametrizada por tiempo (real o efectivo), se consideran dos funcionales principales:

- El tiempo total de viaje, $T(\gamma)$, medido en minutos.
- La exposición acumulada a NO_2, $E(\gamma)$, definida de forma simplificada como una suma de la forma

$$E(\gamma) \;\approx\; \sum_{k=0}^{N-1} c_{\mathrm{NO_2}}(x_k, t_k)\,\Delta t_k,$$

  donde $c_{\mathrm{NO_2}}(x_k, t_k)$ es la concentración de NO_2 interpolada (mediante IDW) en el punto de la ruta x_k y en el instante t_k, y Δt_k es el tiempo empleado en el tramo entre x_k y x_{k+1}. Esta expresión generaliza el funcional $\mathcal{E}_{t_0}(r)$ definido en el Capítulo 4: si el campo se mantiene congelado en un instante t_0 (es decir, $t_k \equiv t_0$ para todo k), entonces $E(\gamma) = \mathcal{E}_{t_0}(\gamma)$, el caso correspondiente a las rutas estáticas; en la ruta dinámica LSTM, t_k varía con la posición a lo largo de la ruta, recogiendo así la evolución temporal del campo de NO_2.

De este modo, dado un par origen–destino (OD), cada ruta γ queda caracterizada por el par $(T(\gamma), E(\gamma))$. Para comparar dos rutas γ^* y γ_{ref} con el mismo origen y destino se emplea la mejora relativa en exposición,

$$\Delta E(\gamma^*, \gamma_{\mathrm{ref}}) \;=\; \frac{E(\gamma_{\mathrm{ref}}) - E(\gamma^*)}{E(\gamma_{\mathrm{ref}})} \times 100\,\%,$$

junto con el número de casos, sobre los 10 estudiados, en los que dicha mejora es efectivamente positiva, es decir, $\#\{E(\gamma^*) < E(\gamma_{\mathrm{ref}})\}/10$. Esta segunda cantidad indica en cuántos pares OD la estrategia γ^* reduce la exposición respecto de γ_{ref}; el tiempo de viaje asociado a cada estrategia se reporta por separado en cada tabla, sin que ambas magnitudes se combinen en una única relación de comparación entre rutas.
En los experimentos se comparan tres tipos de rutas:

- **Ruta estática de mínima exposición**, denotada $\gamma_{\mathrm{stat}}^{\mathrm{expo}}$: se optimiza $E(\gamma)$ sobre una red viaria fija, utilizando un campo de NO_2 congelado en un instante inicial t_0 (campo observado o campo medio GAN, según el escenario).

- **Ruta estática de mínimo tiempo**, denotada $\gamma_{\text{stat}}^{\text{time}}$: se optimiza el tiempo de viaje $T(\gamma)$ sin considerar la contaminación, es decir, como una ruta "clásica" de menor duración.
- **Ruta dinámica LSTM**, denotada $\gamma_{\text{dyn}}^{\text{LSTM}}$: la ruta se construye *por etapas* a partir de predicciones LSTM de NO_2 a distintos horizontes, replanificando periódicamente el tramo siguiente en función del campo previsto en los instantes futuros.

En todos los casos, la red viaria se obtiene de OpenStreetMap restringida al modo `walk`, con un buffer espacial en torno al segmento OD, y la interpolación espacial de NO_2 se realiza mediante IDW con parámetros $(r, k, p) = (3\text{ km},\ 3,\ 2.6)$, consistentes con el capítulo de metodología. La velocidad peatonal efectiva se fija en $v = 4.8$ km/h.
Antes de entrar en los casos de estudio conviene precisar el alcance de la evaluación empírica. Las pruebas recogidas en este capítulo deben interpretarse como *estudios de caso representativos*, donde varían parámetros como horas del día y ubicación. El objetivo de esta sección es mostrar con claridad cómo se comporta el pipeline en situaciones concretas y comparables, dejando una evaluación agregada de gran escala como línea natural de trabajo futuro.

7.1 Resultados agregados sin escenario generativo adversario

Para evitar conclusiones apoyadas en ejemplos aislados, el análisis final se ha reformulado sobre un conjunto de **10 casos representativos sin escenario generativo adversario**. En cada caso se comparan la ruta de tiempo mínimo, la ruta de mínima exposición obtenida mediante un campo estático interpolado por ponderación inversa de la distancia en el instante inicial y finalmente la ruta que utiliza LSTM para predecir el comportamiento de la contaminación en el tiempo, y se interpola en cada instante. El objetivo es determinar, en un escenario habitual para la ciudad, qué reducción de exposición puede obtenerse mediante las dos rutas alternativas, así como comparar ambas estrategias entre sí.
La Tabla 7.1 resume los resultados agregados de estos diez casos. Dado que $E(\gamma) = \sum_{e\in\gamma} \widehat{C}_t(\mathbf{x}_e)\, L_e/v$, sus unidades son ($\mu$g/m^3)·h; los valores numéricos del orden de 10^5 corresponden a esta magnitud acumulada sobre toda la ruta.

Cuadro 7.1: Resumen agregado de los 10 casos sin escenario GAN. Se reportan media $\pm$ desviación típica de las métricas principales.

Estrategia	$\bar{L} \pm \sigma_L$ **(km)**	$\bar{T} \pm \sigma_T$ **(min)**	$\bar{E} \pm \sigma_E$	**Mejora** $\bar{E}$ **vs. tiempo**	$\#\{E(\gamma^*) < E(\gamma_{\text{ref}})\}/10$
Ruta de tiempo mínimo	7.34 ± 2.1	91.77 ± 26.3	187028 ± 41200	–	–
Mínima exposición (IDW estático)	7.88 ± 2.3	98.48 ± 28.7	173998 ± 38100	6.97%	10/10 vs. tiempo
Dinámica con LSTM	9.12 ± 2.6	114.06 ± 32.4	185148 ± 40500	1.01%	8/10 vs. tiempo; 0/10 vs. IDW

Estos resultados muestran una pauta consistente en todos los casos analizados. La ruta de mínima exposición basada en un campo estático inicial reduce la exposición media respecto de la ruta de tiempo mínimo en los diez casos, con una mejora del 6.97% en la exposición acumulada media a costa de un incremento moderado del tiempo de viaje (aproximadamente un 7%). La ruta dinámica con LSTM mejora ligeramente la exposición frente a la ruta de tiempo mínimo, pero no reduce la exposición respecto de la solución estática IDW en ninguno de los diez casos (0/10): en escenarios sin variabilidad temporal acusada, la información predictiva no aporta ventaja sobre el campo interpolado en el instante inicial.

7.2 Resultados agregados con escenario generativo adversario temporal

El segundo bloque experimental refuerza la variabilidad de la contaminación para obtener un estudio más sólido respecto a episodios de contaminación más acusados. Para ello se construye un escenario

GAN estresado, donde la contaminación, a partir de los datos reales, varía imitando un episodio de contaminación en la ciudad, actuando así como una realidad sintética de estrés. Tras esto, definimos 10 rutas en el escenario, con los mismos puntos de partida y destino que las anteriores. En cada caso, la exposición real acumulada de cada ruta se evalúa contra la serie GAN completa, es decir, usando el campo correspondiente al instante efectivo de paso por cada tramo.
La Tabla 7.2 recoge el comportamiento agregado obtenido en estos diez casos.

Cuadro 7.2: Resumen agregado de los 10 casos con escenario GAN temporal. Se reportan media $\pm$ desviación típica.

Estrategia	$\bar{L} \pm \sigma_L$ **(km)**	$\bar{T} \pm \sigma_T$ **(min)**	$\bar{E} \pm \sigma_E$	**Mejora** $\bar{E}$ **vs. tiempo**	$\#\{E(\gamma^*) < E(\gamma_{\text{ref}})\}/10$
Ruta de tiempo mínimo	7.31 ± 2.0	91.38 ± 25.9	237817 ± 52400	–	–
Mínima exposición (IDW estático)	8.99 ± 2.5	112.42 ± 31.8	156197 ± 34200	34.32%	10/10 vs. tiempo
Dinámica con LSTM	9.89 ± 2.8	123.62 ± 35.1	144111 ± 31700	39.40% vs. tiempo; 7.74% vs. IDW	10/10 vs. tiempo; 10/10 vs. IDW

En el escenario con GAN la jerarquía entre estrategias cambia de forma notable. La ruta estática por IDW mejora a la ruta de tiempo mínimo en los diez casos (reducción media del 34% en exposición acumulada), y la ruta dinámica basada en LSTM supera a ambas alternativas en todos los casos. Este resultado es consistente con la tesis principal del trabajo: cuando el campo de contaminación evoluciona de forma dinámica, anticipar su evolución mediante predicción temporal permite diseñar rutas con menor exposición real que asumir un campo congelado en t_0. No obstante, conviene recordar que en el escenario sin GAN esta ventaja desaparece, lo que sugiere que la ganancia de la planificación dinámica depende de la intensidad de la variabilidad espacio-temporal del contaminante.

7.3 Comparación global de ambos experimentos

Para facilitar la lectura conjunta de los dos bloques anteriores, la Tabla 7.3 sintetiza los resultados medios en ambos contextos experimentales.

Cuadro 7.3: Comparación global entre el experimento sin GAN y el experimento con GAN temporal.

Escenario	**Estrategia**	$\bar{L}$ **(km)**	$\bar{T}$ **(min)**	$\bar{E}$	**Mejora vs. tiempo**	$\#\{E(\gamma^*) < E(\gamma_{\text{ref}})\}/10$
Sin GAN	Tiempo mínimo	7.34	91.77	187028	–	–
	Mínima exposición (IDW)	7.88	98.48	173998	6.97%	10/10 vs. tiempo
	Dinámica con LSTM	9.12	114.06	185148	1.01%	8/10 sobre tiempo, 0/10 sobre IDW
Con GAN temporal	Tiempo mínimo	7.31	91.38	237817	–	–
	Mínima exposición (IDW)	8.99	112.42	156197	34.32%	10/10 vs. tiempo
	Dinámica con LSTM	9.89	123.62	144111	39.40% vs. tiempo; 7.74% vs. interpolación estática	10/10 sobre tiempo y 10/10 sobre interpolación estática

La lectura conjunta de la Tabla 7.3 permite extraer dos conclusiones. En primer lugar, la optimización por exposición es útil incluso en el experimento sin GAN, ya que la ruta IDW mejora sistemáticamente a la de tiempo mínimo. En segundo lugar, la ruta dinámica con LSTM sólo despliega toda su ventaja en episodios de alta contaminación, donde puede prever mejor el comportamiento futuro del contaminante.

7.4 Casos representativos para la memoria

Además de las Tablas 7.1 y 7.2, que sintetizan el comportamiento de los diez casos sin GAN y con GAN temporal, para la exposición cualitativa de la memoria se han seleccionado cuatro ejemplos: dos casos sin GAN, en los que la ruta obtenida mediante LSTM apenas modifica la solución estática basada en IDW, y dos casos con GAN, en los que la perturbación temporal genera divergencias mucho más acusadas.
En el bloque *sin GAN* (Figuras 7.1 y 7.2), los casos 06 y 03 sirven para ilustrar las conclusiones anteriores. En ambos ejemplos, las rutas alternativas apenas presentan diferencias geométricas rele-

vantes, por lo que la solución dinámica basada en LSTM queda muy próxima a la solución estática por interpolación IDW.



Figura 7.1: Comparación de rutas peatonales sin generación sintética de escenarios para el trayecto Olivereta–Cabanyal, a las 08:00 h del 10 de julio de 2023. La ruta de mínimo tiempo se representa en naranja, la ruta de mínima exposición IDW en azul oscuro y la ruta de mínima exposición LSTM e interpolación espacial en turquesa; el punto de partida aparece en verde y el destino en rojo. En este caso, las dos rutas de mínima exposición siguen trayectorias muy similares y mejoran claramente la exposición acumulada respecto a la ruta de mínimo tiempo.



Figura 7.2: Comparación de rutas peatonales sin generación sintética de escenarios para el trayecto Olivereta–Politècnic, a las 08:00 h del 16 de enero de 2023. La ruta de mínimo tiempo aparece en naranja, la ruta de mínima exposición IDW en azul oscuro y la ruta de mínima exposición LSTM e interpolación espacial en turquesa; el origen y el destino se marcan, respectivamente, en verde y rojo. Las dos rutas de mínima exposición son prácticamente coincidentes y presentan una exposición acumulada inferior a la de la ruta de mínimo tiempo.

Por el contrario, en el bloque *con GAN temporal* (Figuras 7.3 y 7.4) aparecen situaciones mucho más exigentes. Los casos 05 y 06 muestran que, cuando el campo de contaminación es sometido a escenarios temporales más severos, la ruta dinámica puede desviarse de manera notable respecto a la solución estática. Esta diferencia no es sólo visualmente llamativa, sino que refuerza la idea central de este trabajo: en presencia de variaciones espaciales y temporales intensas, el uso de una predicción dinámica puede cambiar de forma material el corredor peatonal seleccionado.

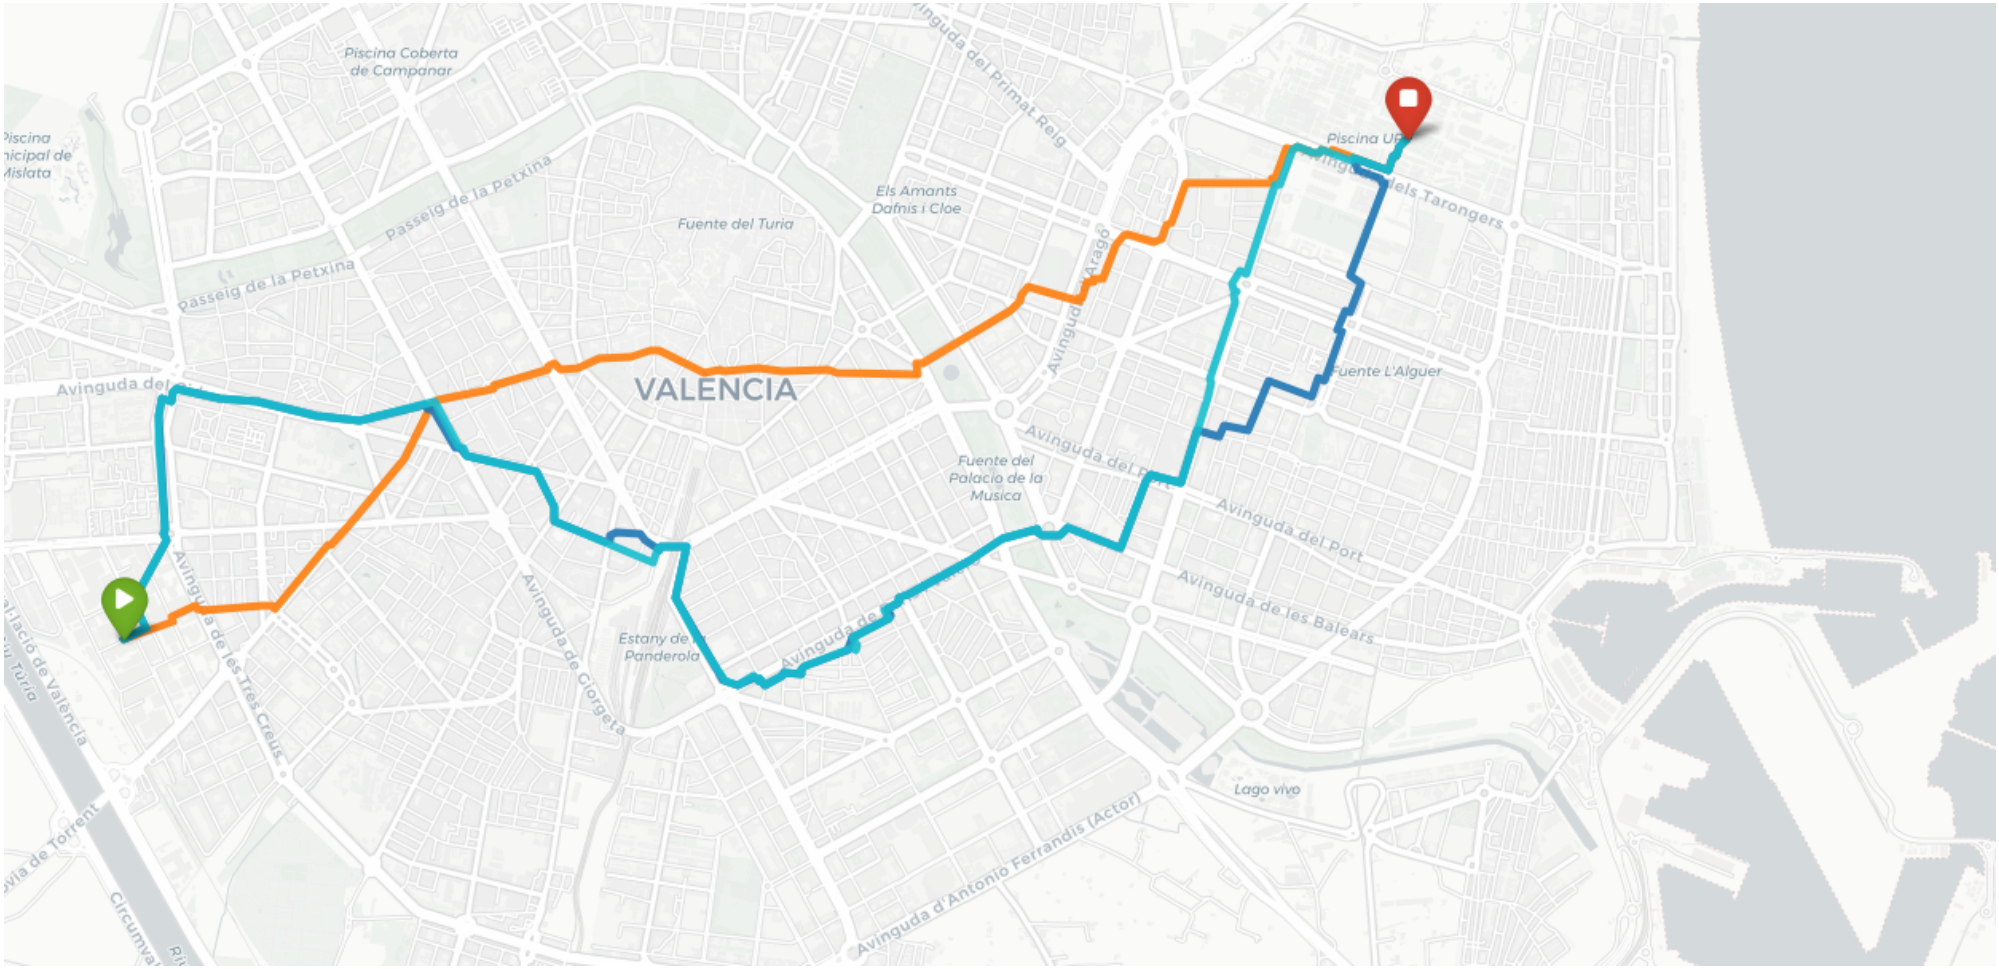


Figura 7.3: Comparación de rutas peatonales en un escenario sintético de contaminación generado mediante una red generativa adversaria para el trayecto Patraix–Politècnic, a las 08:00 h del 21 de marzo de 2023. La ruta de mínimo tiempo se representa en naranja, la ruta de mínima exposición IDW en azul oscuro y la ruta de mínima exposición LSTM e interpolación espacial en turquesa; el punto de partida aparece en verde y el destino en rojo. En este caso, la estrategia LSTM e interpolación espacial proporciona la menor exposición acumulada ($E = 86767.7$), mejorando tanto la solución basada únicamente en IDW ($E = 92824.4$) como, de forma mucho más acusada, la ruta de mínimo tiempo ($E = 214054.9$), aunque a costa de un mayor recorrido y tiempo de viaje.

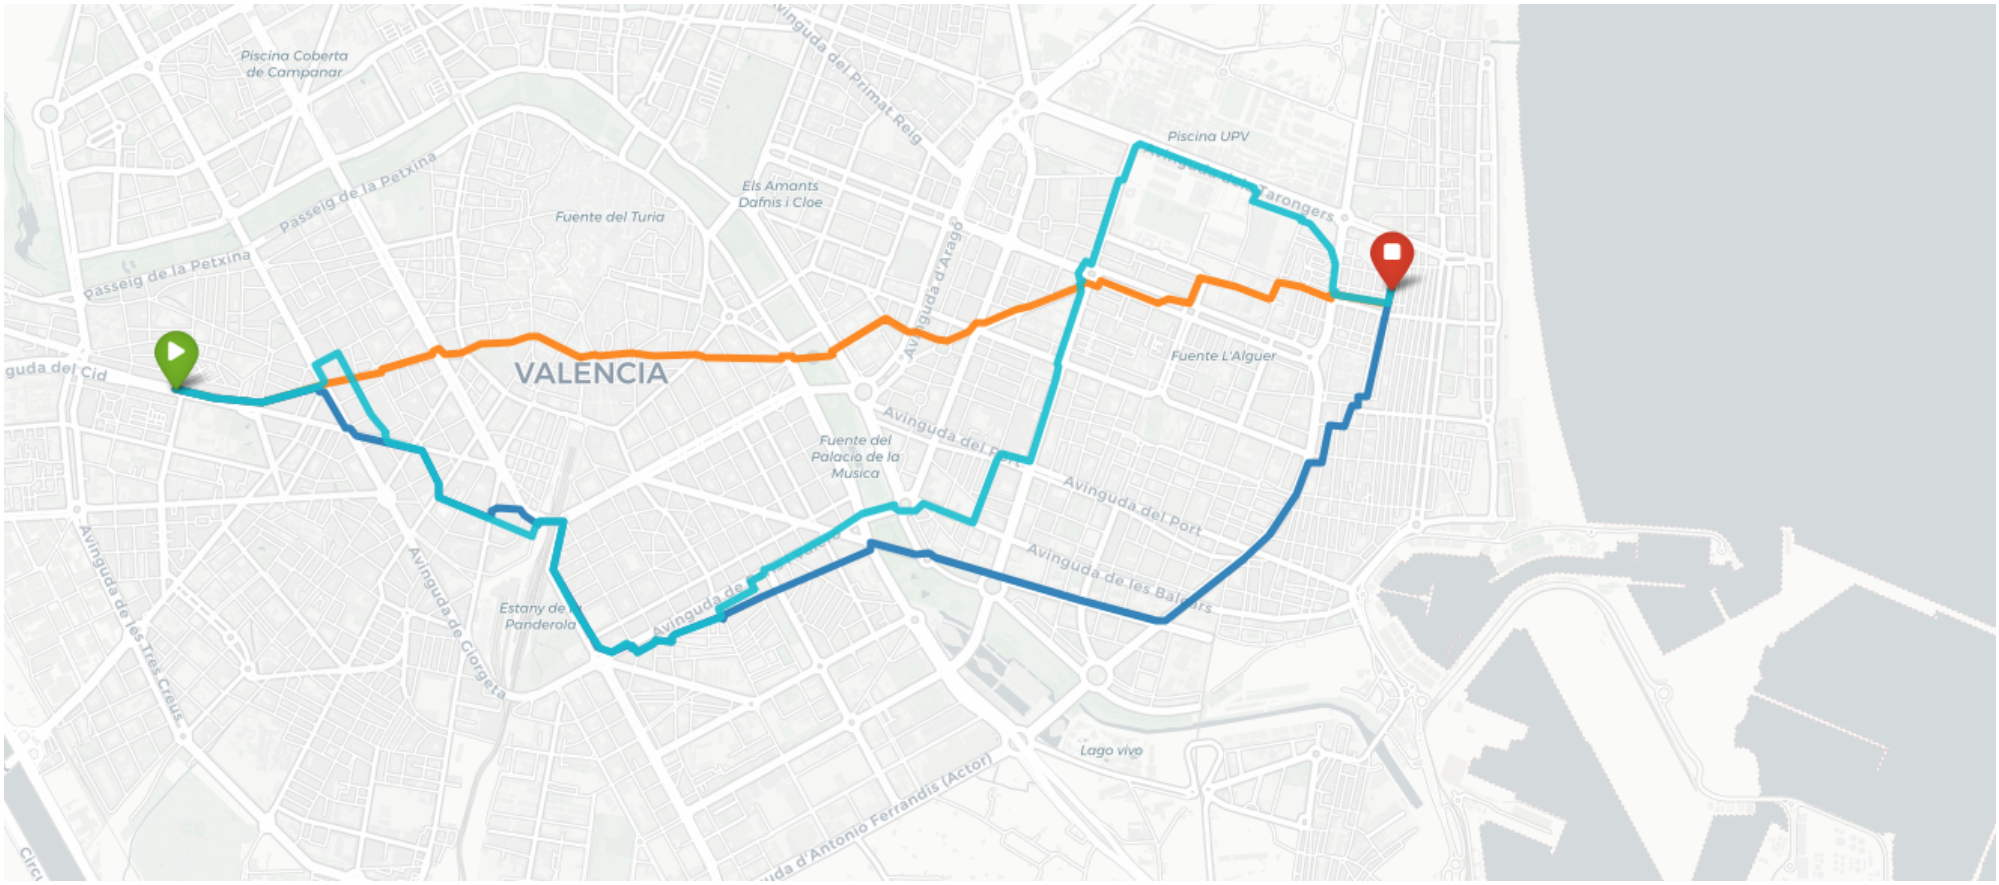


Figura 7.4: Comparación de rutas peatonales en un escenario sintético de contaminación generado mediante una red generativa adversaria para el trayecto Olivereta–Cabanyal, a las 08:00 h del 10 de julio de 2023. La ruta de mínimo tiempo se representa en naranja, la ruta de mínima exposición IDW en azul oscuro y la ruta de mínima exposición LSTM e interpolación espacial en turquesa; el punto de partida aparece en verde y el destino en rojo. En este escenario, la ruta LSTM e interpolación espacial alcanza la menor exposición acumulada ($E = 198405.6$), por debajo de la ruta calculada solo con IDW ($E = 233866.8$) y de la ruta de mínimo tiempo ($E = 264962.5$). Este resultado pone de manifiesto que, bajo escenarios estresados generados con GAN, la incorporación de predicción temporal puede modificar de forma sustancial la geometría de la ruta óptima y reducir la exposición total.

En conjunto, esta selección permite cerrar el capítulo de resultados con una lectura equilibrada: por un lado, se muestran casos estables en los que IDW y LSTM prácticamente coinciden; por otro, se documentan escenarios estresados donde la modelización dinámica produce rutas claramente distintas. Esta dualidad es especialmente útil para la memoria, ya que permite argumentar no sólo cuándo la aproximación dinámica aporta valor, sino también cuándo la solución estática resulta suficientemente consistente.

Capítulo 8

Conclusiones y líneas futuras

En este capítulo se sintetizan las principales aportaciones del trabajo y se discuten sus limitaciones y posibles extensiones. El hilo conductor ha sido el diseño de un *pipeline* matemáticamente formulado que conecta datos de calidad del aire en València con modelos de aprendizaje profundo y algoritmos de rutas sobre grafos, con el objetivo de minimizar la exposición peatonal a NO_2 en entornos urbanos.

8.1 Resumen de la contribución

De forma esquemática, las contribuciones del trabajo pueden agruparse en los siguientes puntos:

- **Preprocesamiento de datos de calidad del aire.** Se ha llevado a cabo una limpieza y unificación de ficheros JSON de calidad del aire a diferentes resoluciones, identificando estaciones fiables, analizando patrones de valores ausentes y seleccionando NO_2 como contaminante de estudio en base a criterios de calidad de datos y relevancia urbana.
- **Marco teórico unificado para aprendizaje profundo y rutas.** Se ha formulado el problema de predicción de NO_2 como una tarea supervisada sobre series temporales, el problema espacial como una interpolación mediante IDW y el problema de rutas como un cálculo de caminos mínimos en un grafo ponderado por un funcional de exposición.
- **Modelos LSTM para predicción temporal de NO_2.** Se ha implementado y analizado un modelo LSTM univariante que, a partir de ventanas temporales de NO_2, predice la concentración futura en horizontes de 60 minutos, siguiendo los principios teóricos descritos en [2, 1].
- **Integración de LSTM e IDW en rutas de mínima exposición.** Las predicciones LSTM se han incorporado al modelo espacial mediante IDW para construir campos previstos de NO_2 y, a partir de ellos, rutas dinámicas de mínima exposición que se recalculan por etapas.
- **Uso de GAN para escenarios de estrés de NO_2.** Se ha empleado una GAN condicional sencilla para generar instantáneas sintéticas de NO_2 a partir de datos reales observados en varios instantes, lo que permite construir escenarios de estrés y evaluar la robustez de las rutas de mínima exposición en situaciones no observadas literalmente en los datos.
- **Evaluación empírica sobre casos de estudio en València.** Se han comparado, para distintos escenarios, rutas de mínimo tiempo, rutas estáticas de mínima exposición y rutas dinámicas informadas por LSTM y evaluadas, en el escenario de estrés, bajo instantáneas generadas por la GAN, cuantificando la reducción de exposición y el incremento de tiempo de viaje asociados a cada estrategia sobre pares origen–destino representativos del mapa urbano de València.

8.2 Conclusiones principales

De los resultados obtenidos se desprenden las siguientes conclusiones:

(a) **El compromiso entre tiempo y salud es cuantificable.** Incluso en escenarios estáticos, la comparación entre rutas de mínimo tiempo y rutas de mínima exposición muestra reducciones claras de la dosis acumulada de NO_2 a costa de aumentos moderados en el tiempo de viaje.

(b) **Los modelos LSTM son capaces de capturar la dinámica de NO_2 a corto plazo.** El modelo LSTM univariante entrenado sobre series históricas de NO_2 produce predicciones razonables, que permiten construir campos espaciales previstos y utilizar esta información para decisiones de ruta. Aunque el trabajo se centra en la integración del modelo en el *pipeline*, los resultados indican que la estructura temporal (picos, valles diarios) es aprendible en la resolución considerada.

(c) **La planificación dinámica aporta beneficios en escenarios con gradientes espacio–temporales acusados.** En el escenario observado sin GAN, la diferencia entre rutas estáticas y dinámicas es modesta, coherente con un campo relativamente suave. Sin embargo, en el escenario de estrés generado por la GAN, la ruta dinámica basada en LSTM, evaluada bajo el escenario generado por la GAN, reduce la exposición acumulada en un 39.40% respecto a la ruta de tiempo mínimo y en un 7.74% adicional respecto a la ruta estática IDW, con un incremento moderado del tiempo de viaje.

(d) **El marco propuesto es extensible a aplicaciones reales en ciudades inteligentes.** La combinación de datos ambientales, modelos secuenciales y algoritmos de rutas constituye un patrón general aplicable a otras ciudades y a otros contaminantes, siempre que se disponga de redes de medida y de grafos viarios suficientemente detallados.

8.3 Limitaciones del estudio

A pesar de los resultados positivos, el trabajo presenta varias limitaciones que conviene destacar:

- **Univariancia y foco exclusivo en NO_2.** Por motivos de calidad de datos y claridad teórica, el estudio se restringe a NO_2. No se modelan explícitamente otros contaminantes relevantes para la salud, como $PM_{2.5}$, PM_{10} u ozono, ni sus posibles interacciones.

- **Resolución espacial limitada por la red de estaciones.** El campo espacial de NO_2 se obtiene interpolando un número finito de estaciones, lo que impone una resolución efectiva ligada a la densidad de la red. En zonas con pocas estaciones el campo interpolado puede infraestimar gradientes locales reales.

- **Sencillez de los modelos generativos.** La GAN utilizada se ha mantenido deliberadamente simple, priorizando la estabilidad y la integración en el *pipeline* sobre la sofisticación arquitectural. No se ha realizado un análisis exhaustivo de calidad generativa (por ejemplo, mediante métricas específicas de divergencia entre distribuciones).

- **Modelo de movilidad peatonal simplificado.** Se asume una velocidad peatonal constante y no se tienen en cuenta restricciones individuales (edad, condiciones físicas) ni factores contextuales (semáforos, obras, preferencias de seguridad). El coste se define únicamente en función de tiempo y exposición a NO_2.

- **Número limitado de casos de estudio.** Aunque los casos analizados son representativos, el número de combinaciones origen–destino y de escenarios es necesariamente limitado. Un estudio estadístico más amplio requeriría automatizar la generación de múltiples OD y días, y resumir los resultados de forma agregada.

8.4 Líneas de trabajo futuro

El trabajo abre varias direcciones de investigación y desarrollo que podrían abordarse en estudios posteriores:

- **Extensión a modelos multivariantes y otros contaminantes.** Un paso natural es incorporar simultáneamente NO_2, $PM_{2.5}$, PM_{10} y otros contaminantes en modelos LSTM o arquitecturas espaciotemporales más avanzadas (por ejemplo, redes neuronales sobre grafos o transformers temporales), de modo que la planificación de rutas tenga en cuenta un vector de riesgos ambientales.

- **Integración de variables meteorológicas.** La calidad del aire está fuertemente influida por condiciones meteorológicas (viento, estabilidad atmosférica, temperatura, etc.). Integrar estas variables como entradas adicionales en el modelo LSTM o en modelos generativos podría mejorar la precisión a la hora de predecir episodios de alta contaminación.

- **Modelos espaciotemporales más ricos.** Más allá de combinar LSTM con IDW, sería interesante explorar modelos que traten conjuntamente espacio y tiempo, como redes convolucionales espaciotemporales o modelos de difusión sobre grafos urbanos, que representen explícitamente el transporte y dispersión de NO_2.

- **Optimización multiobjetivo explícita y personalización.** En lugar de fijar a priori el compromiso tiempo–exposición, se podrían estudiar formulaciones multiobjetivo que generen familias de rutas de Pareto y permitan al usuario seleccionar interactivamente su punto preferido. La inclusión de preferencias individuales (máximo tiempo aceptable, aversión relativa a la contaminación) haría el sistema más realista.

- **Despliegue en tiempo real y aplicaciones móviles.** Desde el punto de vista aplicado, una línea clara es la integración de los modelos en una aplicación que, a partir de datos en tiempo casi real, recomiende rutas peatonales o ciclistas con menor exposición, incorporando actualizaciones conforme cambian las condiciones del tráfico y la calidad del aire.

En conjunto, los resultados de este Trabajo Fin de Grado muestran que es posible combinar herramientas matemáticas de interpolación, modelos de aprendizaje profundo y algoritmos clásicos de grafos para abordar un problema aplicado de interés social: la planificación de rutas que reduzcan la exposición a contaminantes en entornos urbanos. Las extensiones propuestas apuntan hacia un marco más amplio en el que estos modelos puedan contribuir de forma significativa a la construcción de ciudades más saludables e inteligentes.

Bibliografía

[1] Raschka, S., Liu, Y. y Mirjalili, V. (2022). *Machine Learning with PyTorch and Scikit-Learn*. Packt Publishing.

[2] Goodfellow, I., Bengio, Y. y Courville, A. (2016). *Deep Learning*. MIT Press.

[3] Raschka, S. y Mirjalili, V. (2019). *Python Machine Learning* (3.ª ed.). Packt Publishing.

[4] Hochreiter, S. y Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.

[5] Gers, F. A., Schmidhuber, J. y Cummins, F. (2000). Learning to forget: Continual prediction with LSTM. En *Proceedings of the 9th International Conference on Artificial Neural Networks* (pp. 850–855).

[6] Shepard, D. (1968). A two-dimensional interpolation function for irregularly-spaced data. *Proceedings of the 1968 23rd ACM National Conference*, 517–524.

[7] Li, J. y Heap, A. D. (2008). *A review of spatial interpolation methods for environmental scientists* (Record 2008/23). Geoscience Australia.

[8] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. y Bengio, Y. (2014). Generative adversarial nets. En *Advances in Neural Information Processing Systems* (Vol. 27).

[9] Hatzopoulou, M., Weichenthal, S., Barreau, G., Goldberg, M., Farrell, W., Crouse, D. y Ross, N. (2013). A web-based route planning tool to reduce cyclists' exposures to traffic pollution: A case study in Montreal, Canada. *Environmental Research*, 123, 58–61. https://doi.org/10.1016/j.envres.2013.03.004

[10] Helle, J., Poom, A., Willberg, E. y Toivonen, T. (2023). The Green Paths route planning software for exposure-optimised active travel. *Journal of Open Research Software*, 11(1). https://doi.org/10.5334/jors.400

[11] Bistaffa, F. y Calo Oliveira, S. (2025). Recommending green routes for pedestrians to reduce the exposure to air pollutants in Barcelona. En *Proceedings of the 24th International Conference on Autonomous Agents and Multiagent Systems*.

[12] Gueye, A., Niang, S. A. A., Diallo, I., Dramé, M. S., Diallo, M. y Younous, A. A. (2025). On the application of Long Short-Term Memory neural network for daily forecasting of PM2.5 in Dakar, Senegal (West Africa). *Sustainability*, 17(12), 5421. https://doi.org/10.3390/su17125421

[13] Zhang, A. y otros. (2022). Good environmental governance: Predicting PM2.5 by using spatio-temporal matrix factorization generative adversarial network. *Frontiers in Environmental Science*, 10, 981268. https://doi.org/10.3389/fenvs.2022.981268

[14] Caragliu, A., Del Bo, C. y Nijkamp, P. (2011). Smart cities in Europe. *Journal of Urban Technology*, 18(2), 65–82.

[15] World Health Organization. (2021). *WHO global air quality guidelines: Particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. World Health Organization.

[16] Hoek, G., Krishnan, R. M., Beelen, R., Peters, A., Ostro, B., Brunekreef, B. y Kaufman, J. D. (2013). Long-term air pollution exposure and cardio-respiratory mortality: A review. *Environmental Health*, 12(43), 1–15.

[17] València Innovation Capital. (2024). *El proyecto de inteligencia artificial CitCom.AI se instala en el nuevo edificio de La Harinera*. https://valenciainnovationcapital.com/el-proyecto-de-inteligencia-artificial-citcom-ai-se-instala-en-el-nuevo-edificio-de-la-harinera/